Previsão das idades dos fósseis.

Regressão Linear Múltipla

Leonardo Pinheiro de Siqueira Alves Rangel
Rhana Gomes de Santana Santos
Stefane Moraes Castoldi

01 Contextualização

02 Análise Exploratória

03 Nossos Modelos

04 Resíduos

05 Regressão Ridge

06 Regressão Lasso

modelo

- **Variável Resposta** (Y_i) -> age: Idade calculada dos fósseis, em anos.

$$Y_i = \beta_0 + \beta_1 x_{i1} \ + \ \ldots \ + \ \beta_{18} x_{i18} + e_i$$

$$i = 1, 2, \ldots, 4398$$

$$e_i \sim N(0, \sigma^2)$$

Variáveis Quantitativas:

- **x1 → uranium lead ratio**: Proporção de isótopos de urânio para chumbo na amostra do fóssil.
- **x2 → carbon 14 ratio**: Proporção de isótopos de carbono-14 presentes na amostra do fóssil.
- **x3 → radioactive decay series**: Medição da série de decaimento dos isótopos pai para filho.
- **x4 → stratigraphic layer depth**: Profundidade do fóssil dentro da camada estratigráfica, em metros.
- **x5 → isotopic composition**: Proporção de diferentes isótopos dentro da amostra do fóssil.
- **x6 → fossil size**: Tamanho do fóssil, em centímetros.
- **x7 → fossil weight**: Peso do fóssil, em gramas.

Variáveis Categóricas:

- **x8 à x11 -> surrounding rock type**: Tipo de rocha ao redor do fóssil.
  - **x8** → Arenito
  - **x9** → Xisto
  - **x10** → Calcário
  - **x11** → Conglomerado
- **x12 à x15 -> paleomagnetic data:** Dados de orientação paleomagnética do sítio fóssil.
  - **x12** → Fundo
  - **x13** → Meio
  - **x14** → Topo
- **x15 e x16 -> stratigraphic position:** Posição do fóssil dentro da coluna estratigráfica.
  - **x15** → Polaridade normal
  - **x16** → Polaridade invertida
- **x17 e x18 -> inclusion_of_other_fossils:** inclusão de outros fósseis.
  - **x17** → True
  - **x18** → False

Análise exploratória

Histograma dos **dados quantitativos** e da **variável resposta** em relação à densidade dos dados:

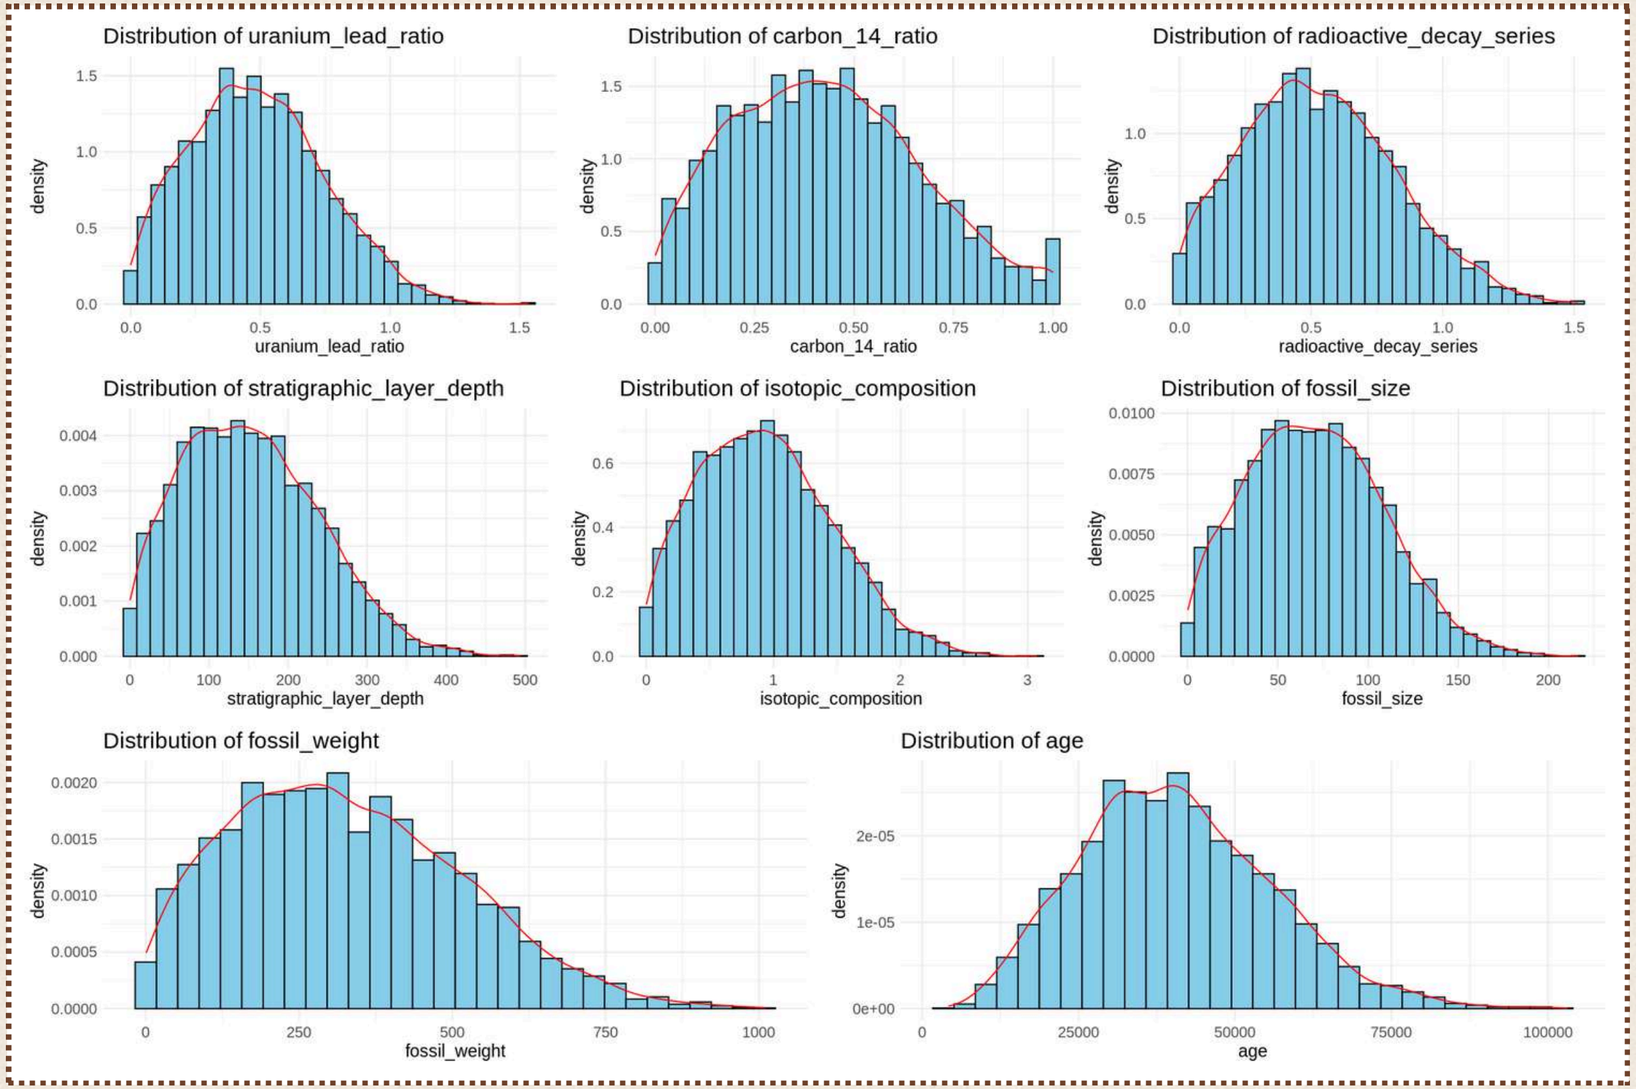

Análise exploratória

Histograma da **variável resposta idade** com a curva de densidade.

- Apesar da curva de densidade parecer normal, podemos identificar **assimetria**!

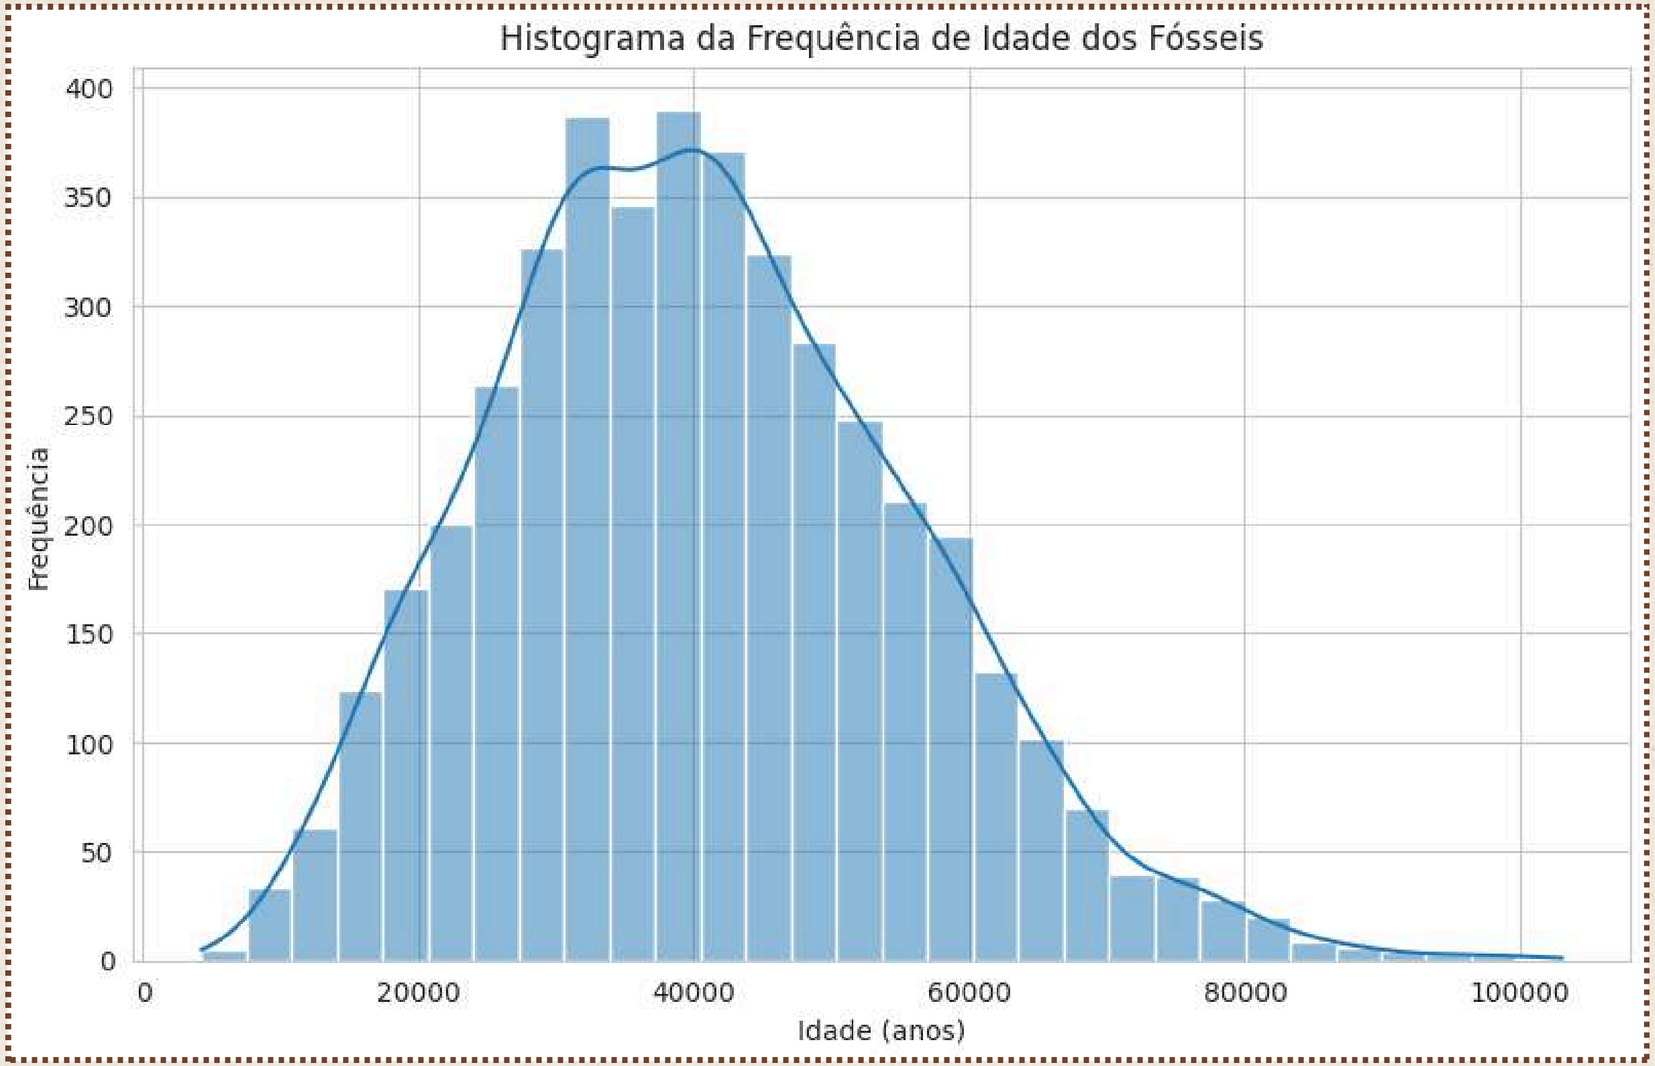

Análise exploratória

Correlação Linear entre os atributos e a resposta

- As variáveis com mais correlação linear com a resposta (age) são os atributos **uranium_lead_ratio** (0.88) seguido da **stratigraphic_layer_depth** (0.33)

- Não parece haver correlação significativa entre os atributos!

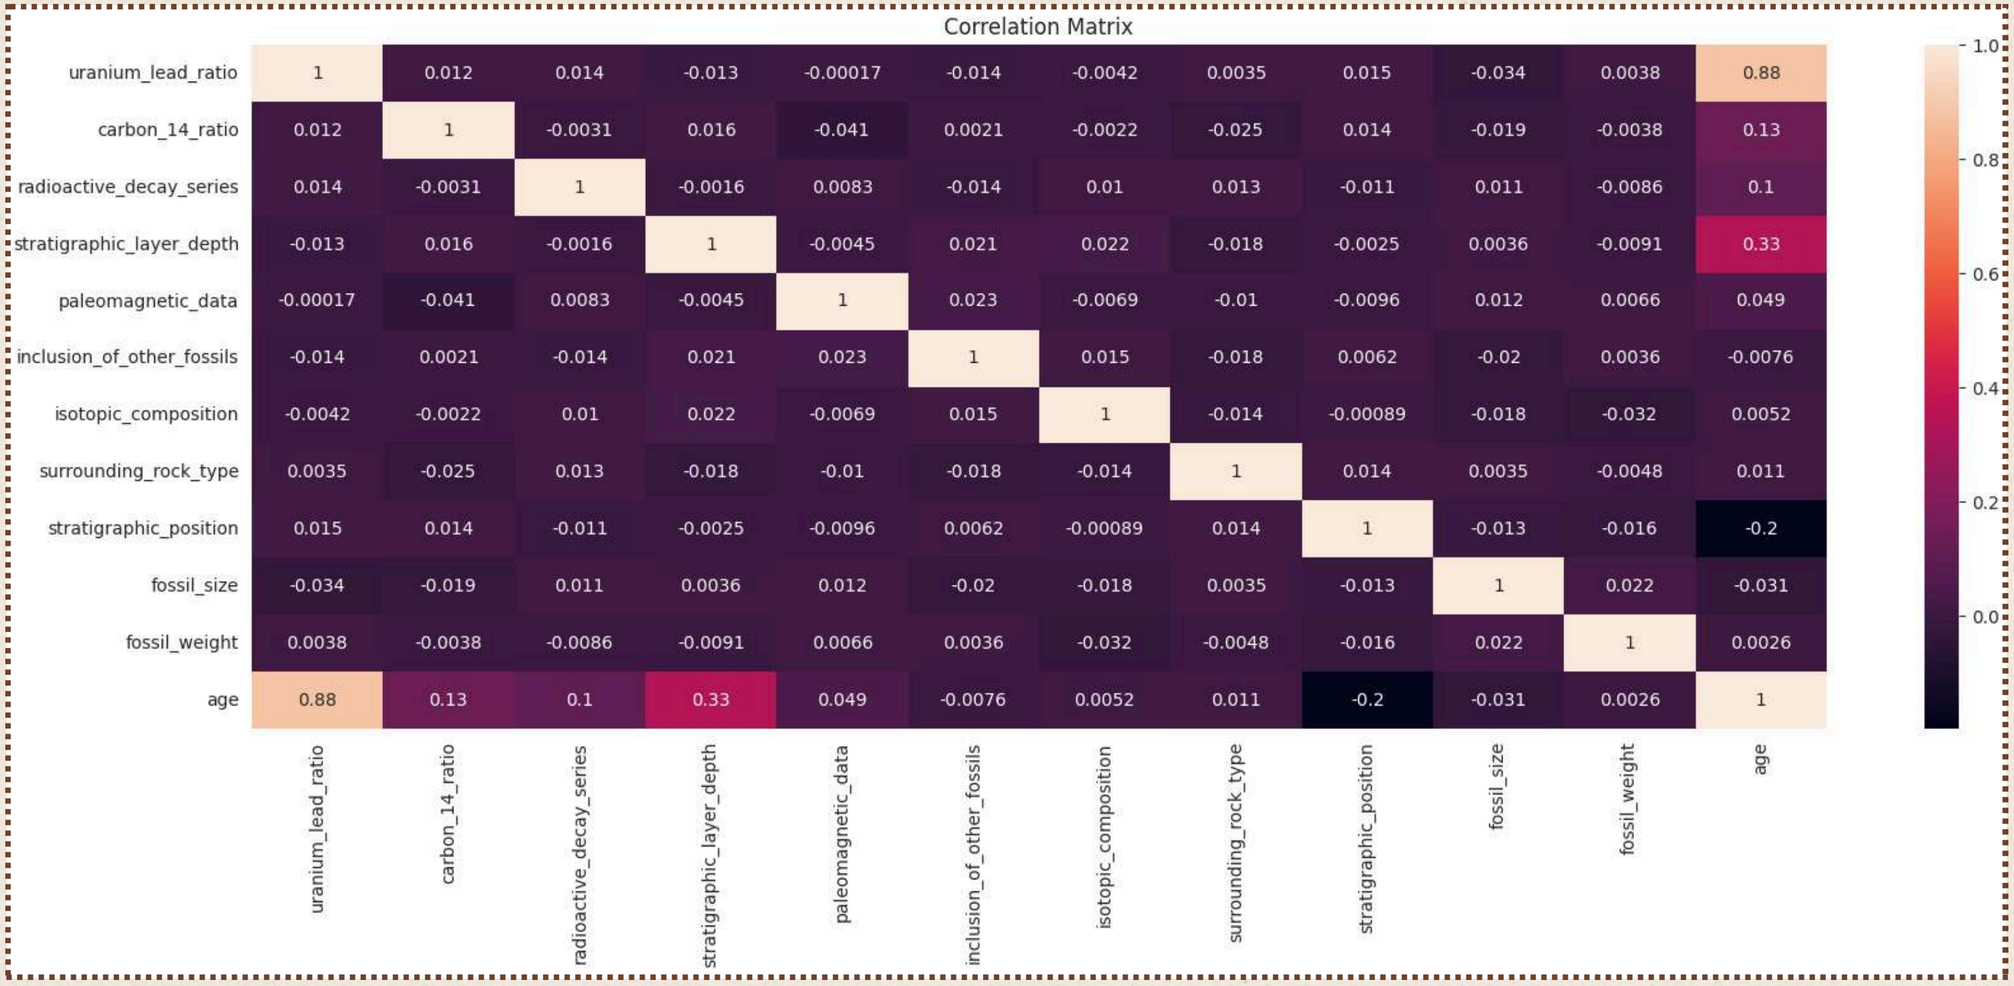

Correlação Linear entre os atributos e a resposta e o **gráfico de dispersão** de cada variável quantitativa

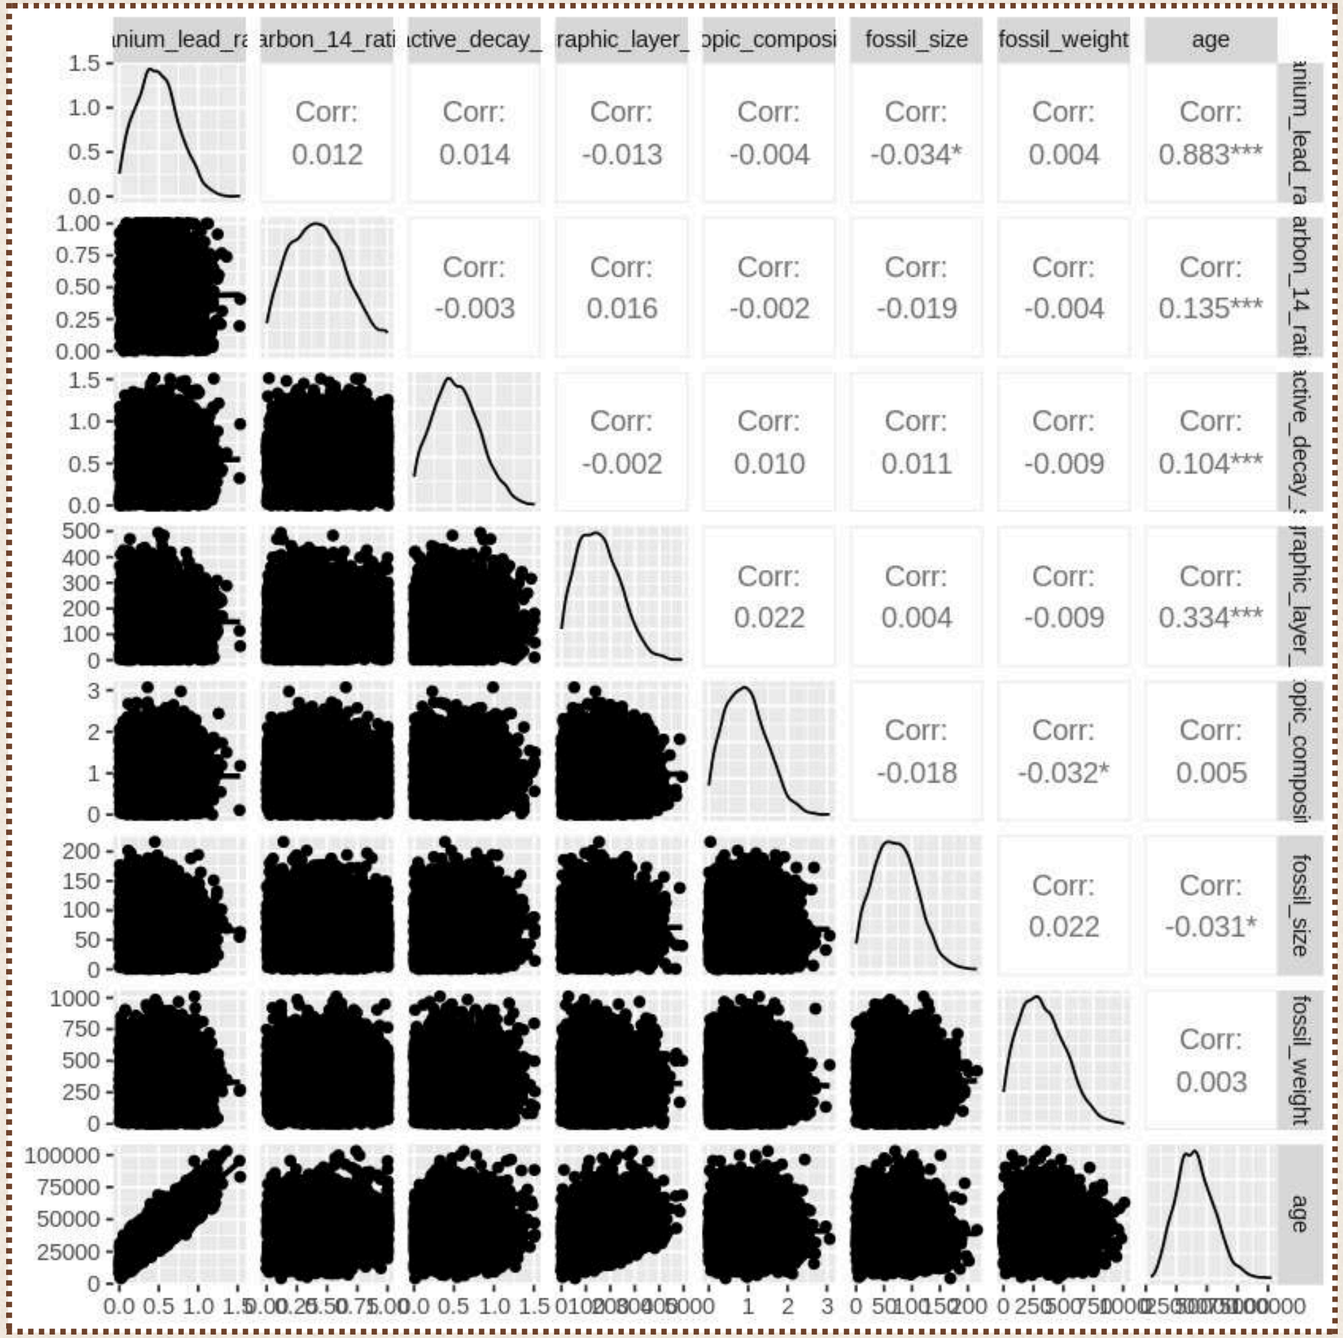

Análise exploratória

Gráfico de dispersão entre a **variável resposta** e a variável quantitativa **Uranium_lead_ratio**

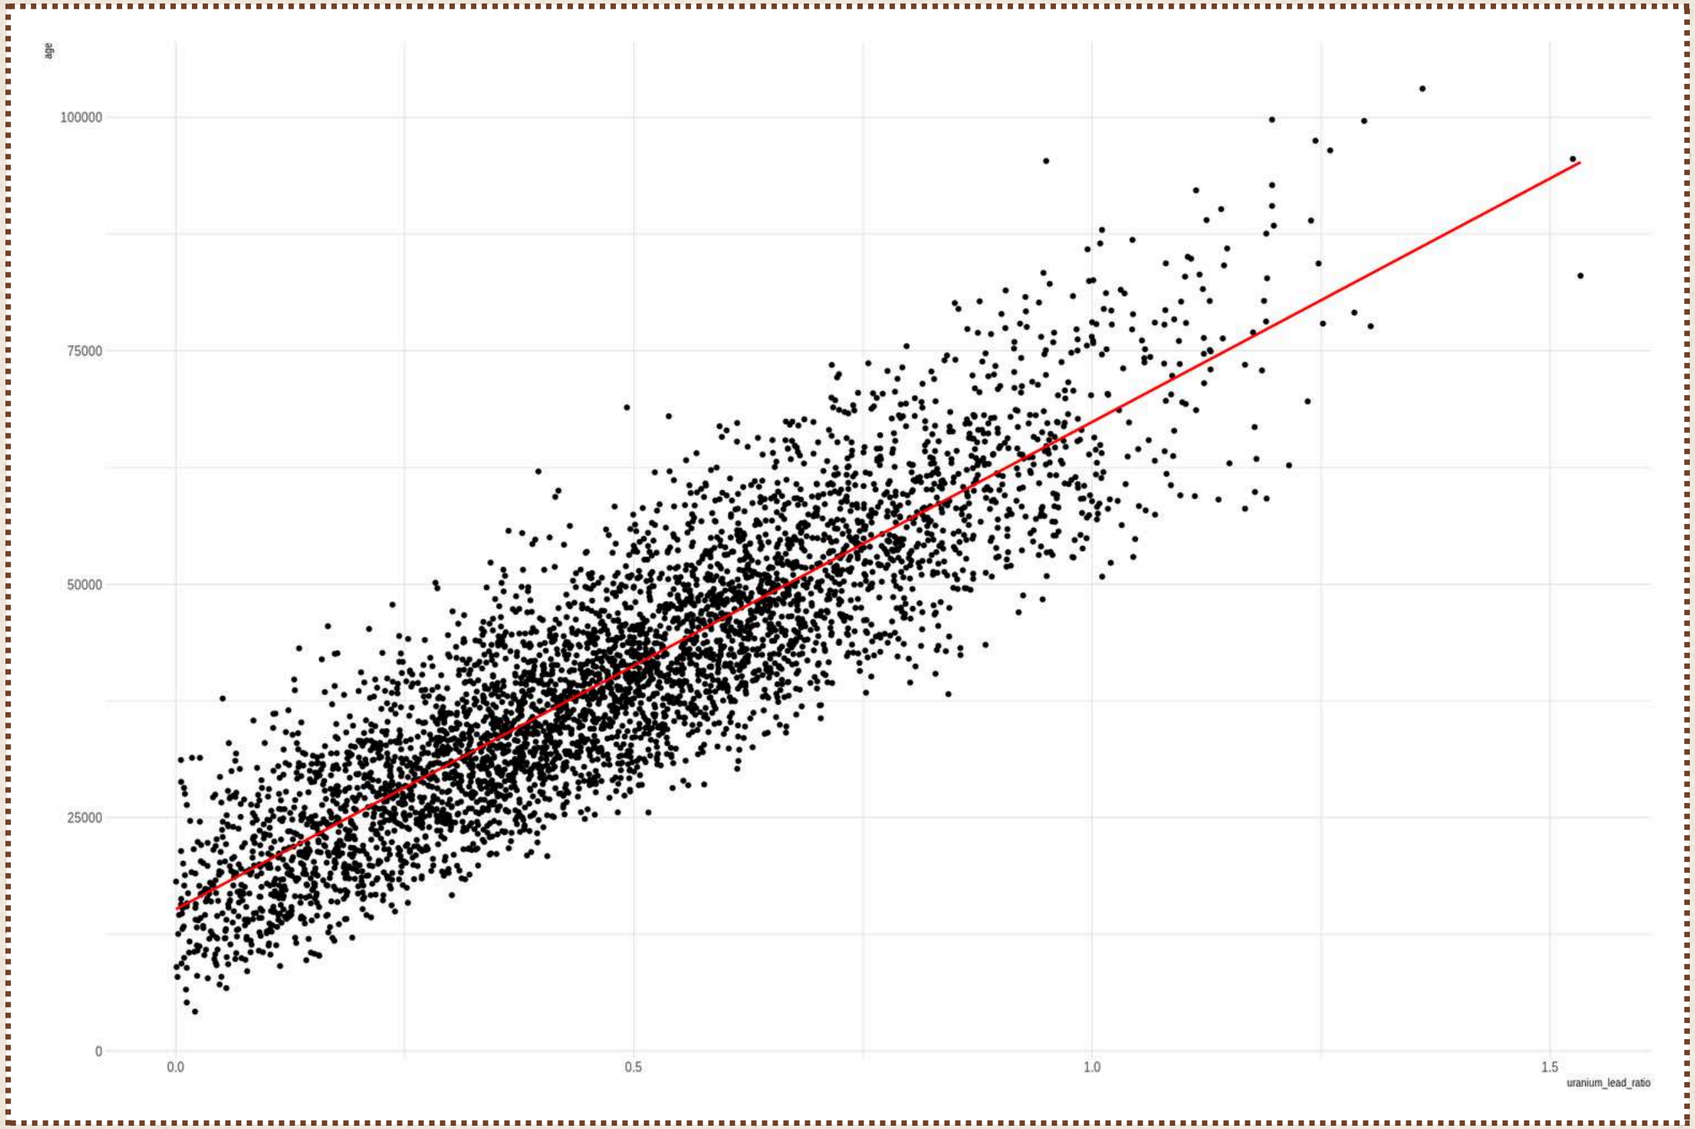

Análise exploratória

Gráfico de dispersão entre a **variável resposta** e a variável quantitativa **Stratigraphic_layer_depth**

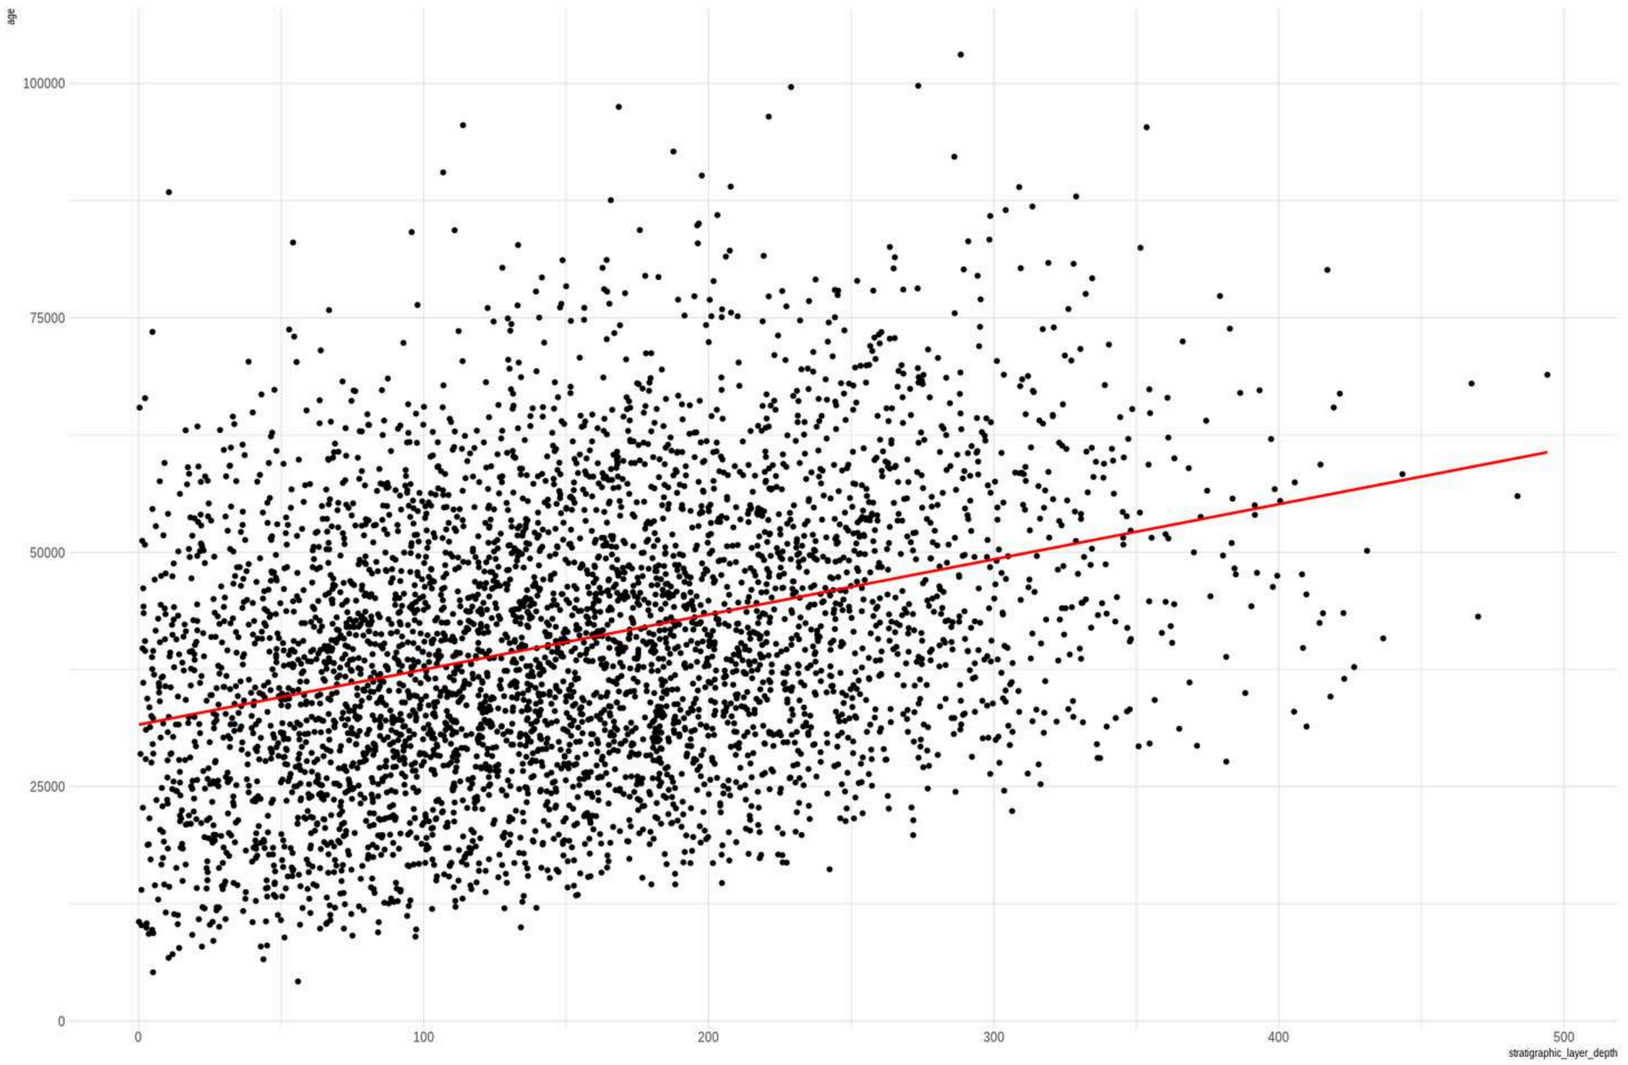

Análise exploratória

Boxplot entre a **variável resposta** e a variável qualitativa **Stratigraphic_position**

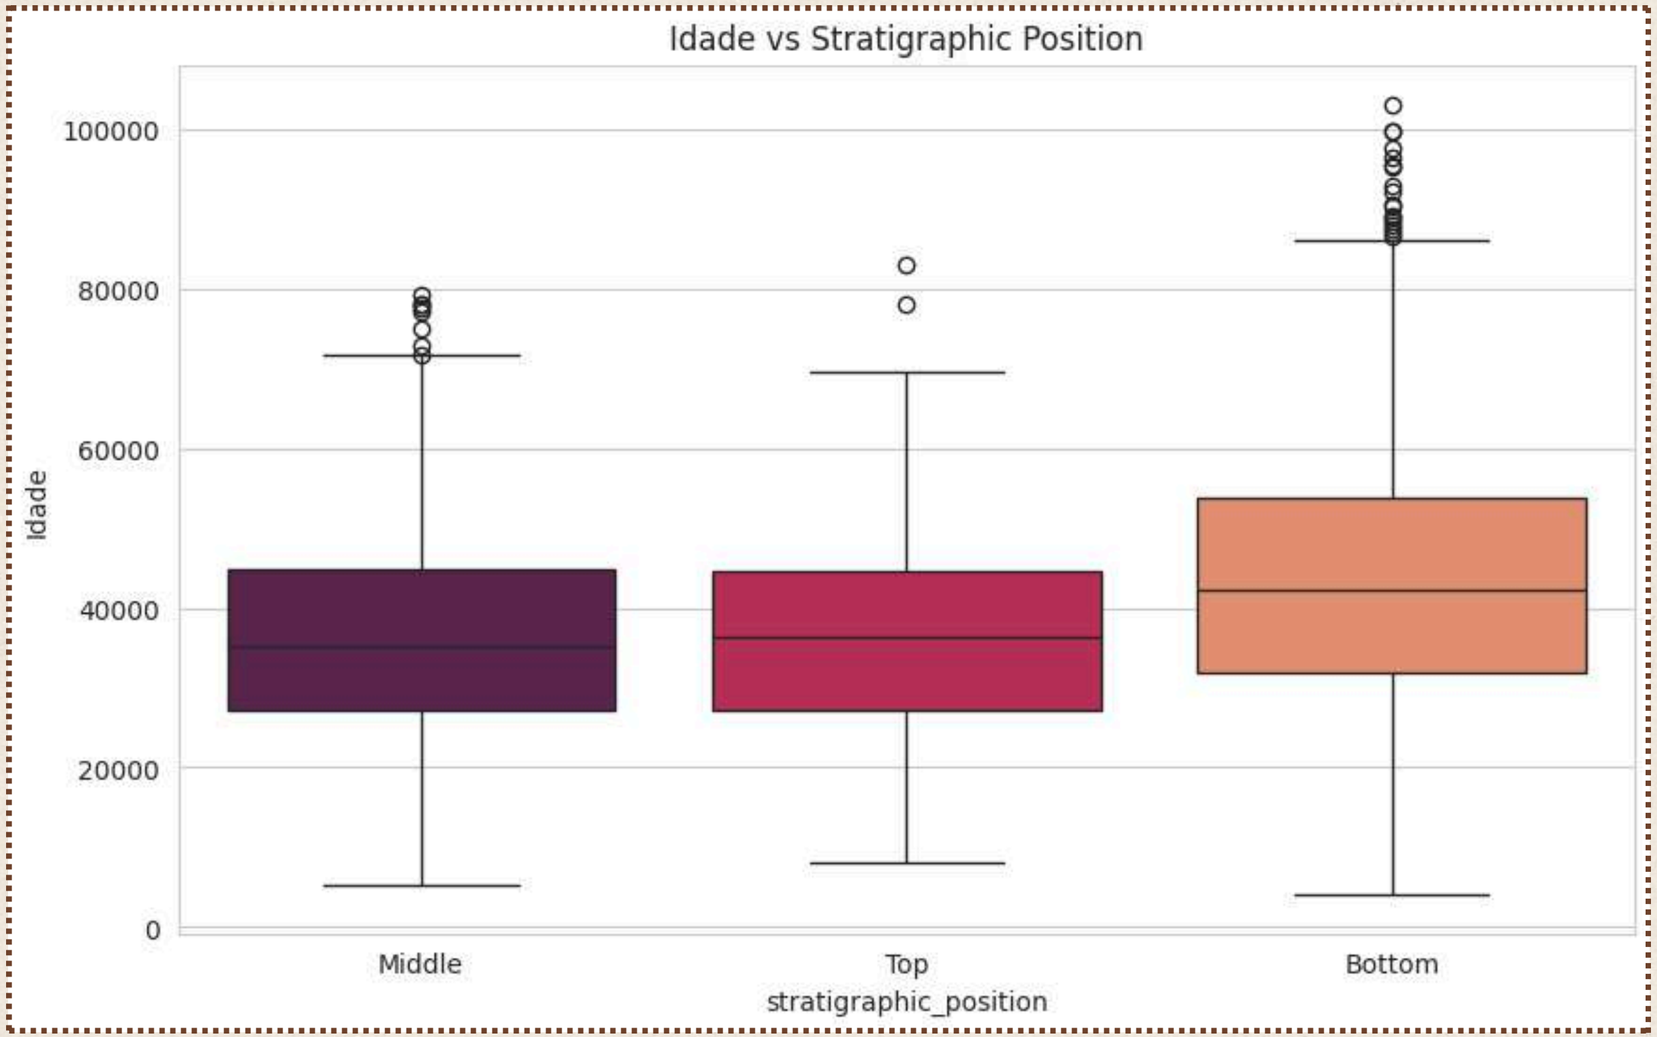

Modelo

```
Call:
lm(formula = age ~ uranium_lead_ratio + carbon_14_ratio + radioactive_decay_series +
    stratigraphic_layer_depth + paleomagnetic_data + inclusion_of_other_fossils +
    isotopic_composition + surrounding_rock_type + stratigraphic_position +
    fossil_size + fossil_weight, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-9099.3 -1559.4  -122.7  1461.3 11345.2

Coefficients:
                                     Estimate Std. Error t value Pr(>|t|)
(Intercept)                         1.452e+03  1.962e+02   7.401 1.61e-13 ***
uranium_lead_ratio                  5.245e+04  1.320e+02 397.233  < 2e-16 ***
carbon_14_ratio                     8.041e+03  1.455e+02  55.276  < 2e-16 ***
radioactive_decay_series            4.761e+03  1.178e+02  40.405  < 2e-16 ***
stratigraphic_layer_depth           6.078e+01  3.936e-01 154.406  < 2e-16 ***
paleomagnetic_dataReversed polarity 1.836e+03  7.551e+01  24.315  < 2e-16 ***
inclusion_of_other_fossilsTrue     -8.018e+01  6.995e+01  -1.146    0.252
isotopic_composition                2.728e+01  6.514e+01   0.419    0.675
surrounding_rock_typeLimestone      9.114e+02  1.137e+02   8.019 1.36e-15 ***
surrounding_rock_typeSandstone      4.733e+02  1.094e+02   4.327 1.55e-05 ***
surrounding_rock_typeShale          1.225e+03  1.140e+02  10.749  < 2e-16 ***
stratigraphic_positionMiddle       -7.118e+03  7.676e+01 -92.742  < 2e-16 ***
stratigraphic_positionTop          -7.270e+03  1.132e+02 -64.214  < 2e-16 ***
fossil_size                        -1.089e+00  9.096e-01  -1.197    0.231
fossil_weight                      -1.981e-02  1.816e-01  -0.109    0.913
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2248 on 4383 degrees of freedom
Multiple R-squared:  0.9782,  Adjusted R-squared:  0.9781
F-statistic: 1.404e+04 on 14 and 4383 DF,  p-value: < 2.2e-16
```

Neste primeiro modelo temos todas as regressoras do modelo e percebemos que algumas variáveis **não são significativas** para o modelo :

- **isotopic composition**
- **fossil size**
- **fossil weight**
- **inclusion_of_other_fossils**

Modelo_novo

```
Call:
lm(formula = age ~ uranium_lead_ratio + carbon_14_ratio + radioactive_decay_series +
    stratigraphic_layer_depth + paleomagnetic_data + surrounding_rock_type +
    stratigraphic_position, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-9064.6 -1566.6  -113.7  1474.2 11300.0

Coefficients:
                                      Estimate Std. Error t value Pr(>|t|)
(Intercept)                           1342.8535   159.0324   8.444  < 2e-16 ***
uranium_lead_ratio                   52458.3179   131.9344 397.609  < 2e-16 ***
carbon_14_ratio                       8043.6188   145.4294  55.309  < 2e-16 ***
radioactive_decay_series              4761.7407   117.7846  40.428  < 2e-16 ***
stratigraphic_layer_depth               60.7735     0.3934 154.482  < 2e-16 ***
paleomagnetic_dataReversed polarity  1832.7397    75.4704  24.284  < 2e-16 ***
surrounding_rock_typeLimestone        909.0806   113.5341   8.007 1.49e-15 ***
surrounding_rock_typeSandstone        471.8090   109.3089   4.316 1.62e-05 ***
surrounding_rock_typeShale           1225.1361   113.9554  10.751  < 2e-16 ***
stratigraphic_positionMiddle        -7119.1139    76.7382 -92.771  < 2e-16 ***
stratigraphic_positionTop           -7268.2720   113.1593 -64.230  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2248 on 4387 degrees of freedom
Multiple R-squared:  0.9782,    Adjusted R-squared:  0.9781
F-statistic: 1.966e+04 on 10 and 4387 DF,  p-value: < 2.2e-16
```

Neste **primeiro modelo_novo** temos todas as regressoras do modelo **significativas**

- Podemos observar um **R^2 alto** (indicando proporção da variabilidade total explicada pela regressora x)

$$0 \leq R^2 \leq 1$$

Anova do modelo_novo

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
uranium_lead_ratio	1	792037738786	792037738786	156707.67971	0
carbon_14_ratio	1	15739478838	15739478838	3114.11576	0
radioactive_decay_series	1	8728570042	8728570042	1726.98079	0
stratigraphic_layer_depth	1	119894454209	119894454209	23721.57387	0
paleomagnetic_data	1	3100582037	3100582037	613.46195	0
surrounding_rock_type	3	531437335	177145778	35.04897	0
stratigraphic_position	2	53771372707	26885686354	5319.43532	0
Residuals	4387	22172937322	5054237	NA	NA

Pela anova do modelo podemos perceber que todos os testes **F** deram **valores significativos** para todas as variáveis presente no modelo_novo

Como na Anova a ordem das variáveis importa, optamos por colocar a **Uranium_lead_ratio** em primeiro pois dada a analise exploratória de dados ela parecia tem a melhor capacidade de predizer o modelo

Pontos influentes

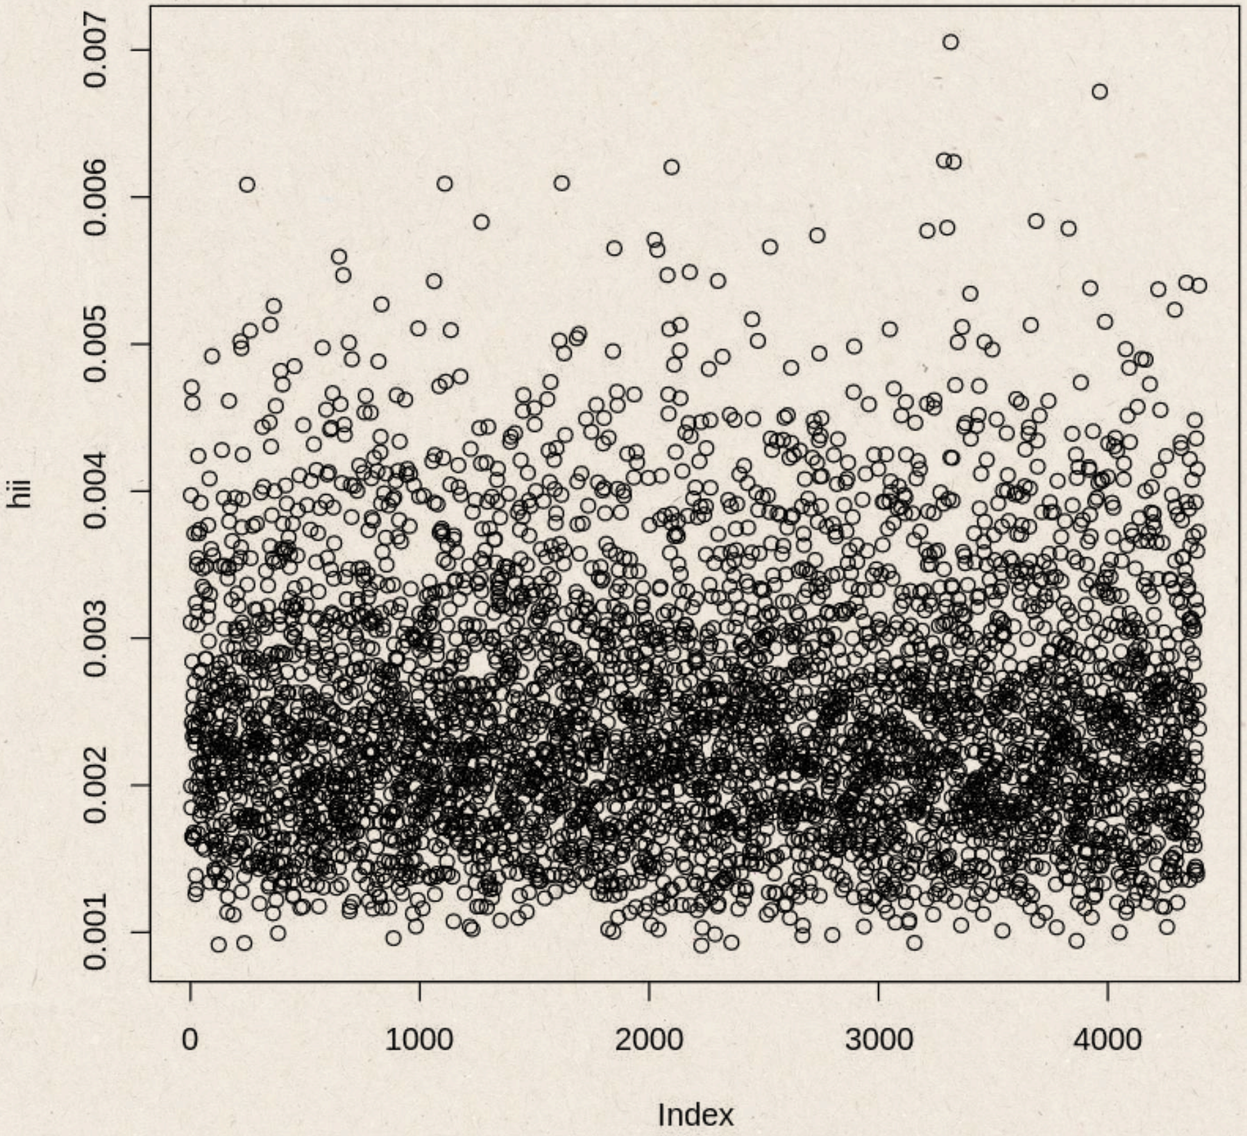

Hii usados para diagnosticar **pontos influentes** em um modelo de regressão linear. (assume valores entre 0 e 1)

Hii = 0: Isso ocorre quando o **ponto i tem nenhuma influência sobre o modelo**. Este valor é possível para pontos que estão bem distantes do centro dos dados ou são observações "comuns".

Como os Hii deram valores baixo não há pontos de influencias no nosso modelo.

Pontos influentes

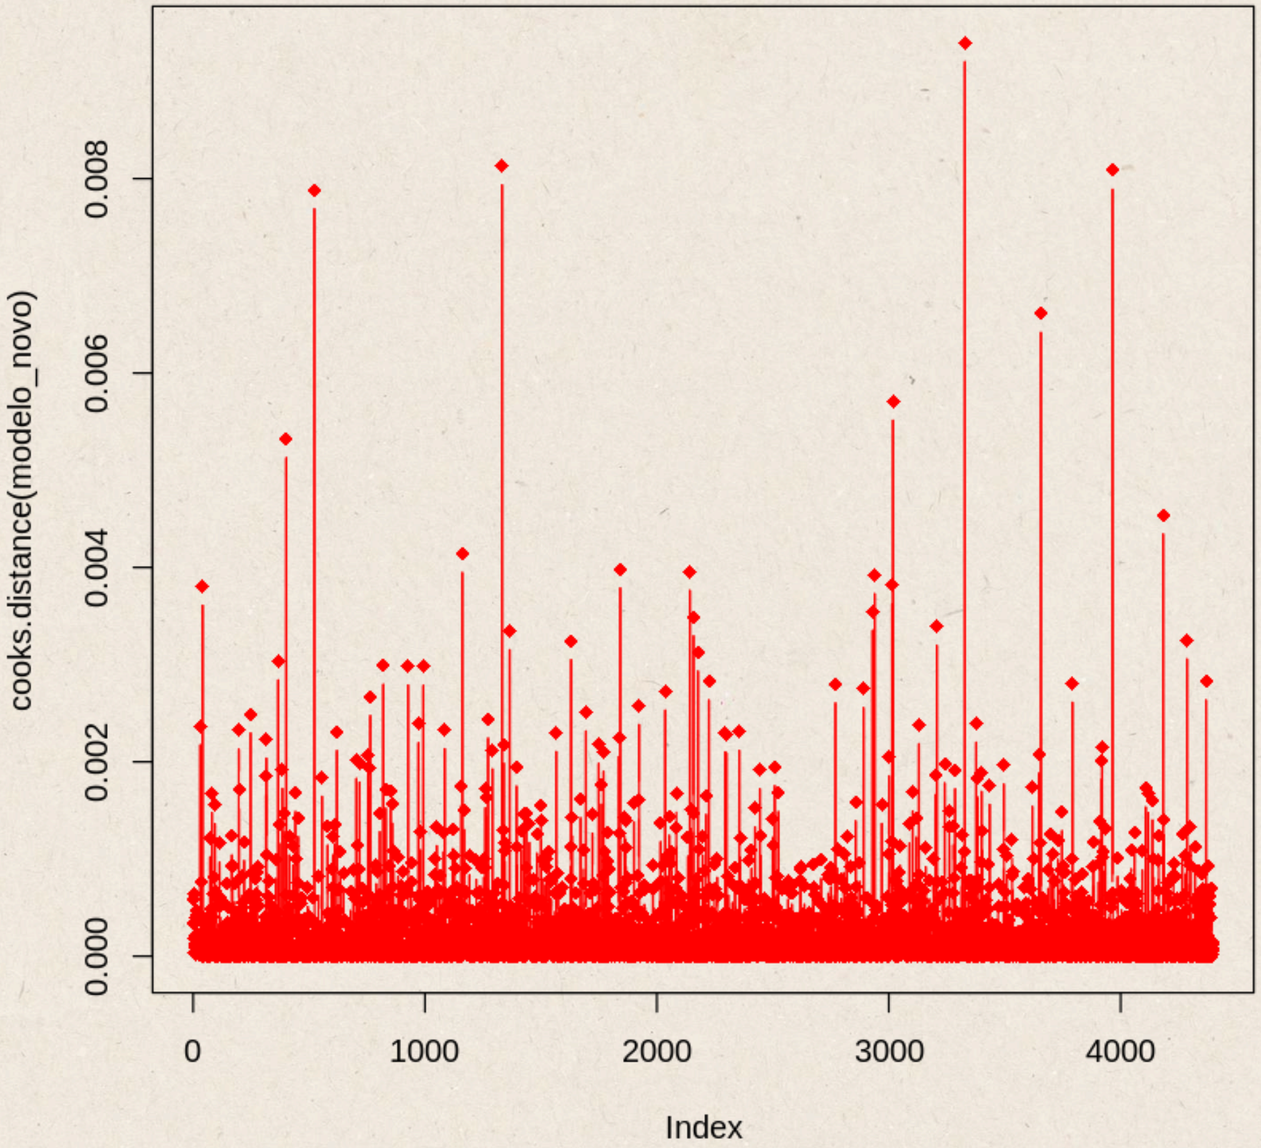

A **Distância de Cook** indica que a observação é potencialmente influente. Um valor típico de corte para a distância de Cook é Di>1:

- Se **Di>1**, a **observação é considerada muito influente** e pode ser um outlier influente.
- Se **Di<1**, a observação tem menos impacto no modelo e não é considerada influente.

Dado esse critério de analise não temos pontos influentes no nosso modelo.

Testes do modelo_novo

```
    Shapiro-Wilk normality test

data:  modelo_novo$residuals
W = 0.99362, p-value = 4.321e-13
```

O teste verifica a **Normalidade dos Erros**, isso é realizamos um teste de hipótese
H0 = distribuição normal
H1 = Não segue uma distribuição Normal
Como p−value < 0.05, **rejeitamos H0** e concluímos que os dados **não seguem uma distribuição normal**.

```
    Anderson-Darling normality test

data:  modelo_novo$residuals
A = 5.5028, p-value = 1.448e-13
```

O teste de mostrar se um conjunto de dados **possui uma distribuição normal**
H0 = distribuição normal
H1 = Não segue uma distribuição Normal
Como o p−value<0.05 há evidências para **rejeitarmos a hipótese H0**, logo, os dados **não seguem a distribuição normal.**

```
    Pearson chi-square normality test

data:  modelo_novo$residuals
P = 107.83, p-value = 2.733e-05
```

O teste é um método estatístico usado para avaliar se há uma **associação entre variáveis categóricas** ou para testar se uma distribuição observada de frequências se ajusta a uma distribuição esperada. Ele testa a qualidade do ajuste, **homogeneidade e independência.**

```
    Durbin-Watson test

data:  modelo_novo
DW = 1.9513, p-value = 0.0531
alternative hypothesis: true autocorrelation is greater than 0
```

O teste verifica se há **autocorrelação dos erros.**
Como o p−value>0.05 conseguimos verificar que **não há autocorrelação entre os resíduos**

Resíduos do modelo_novo

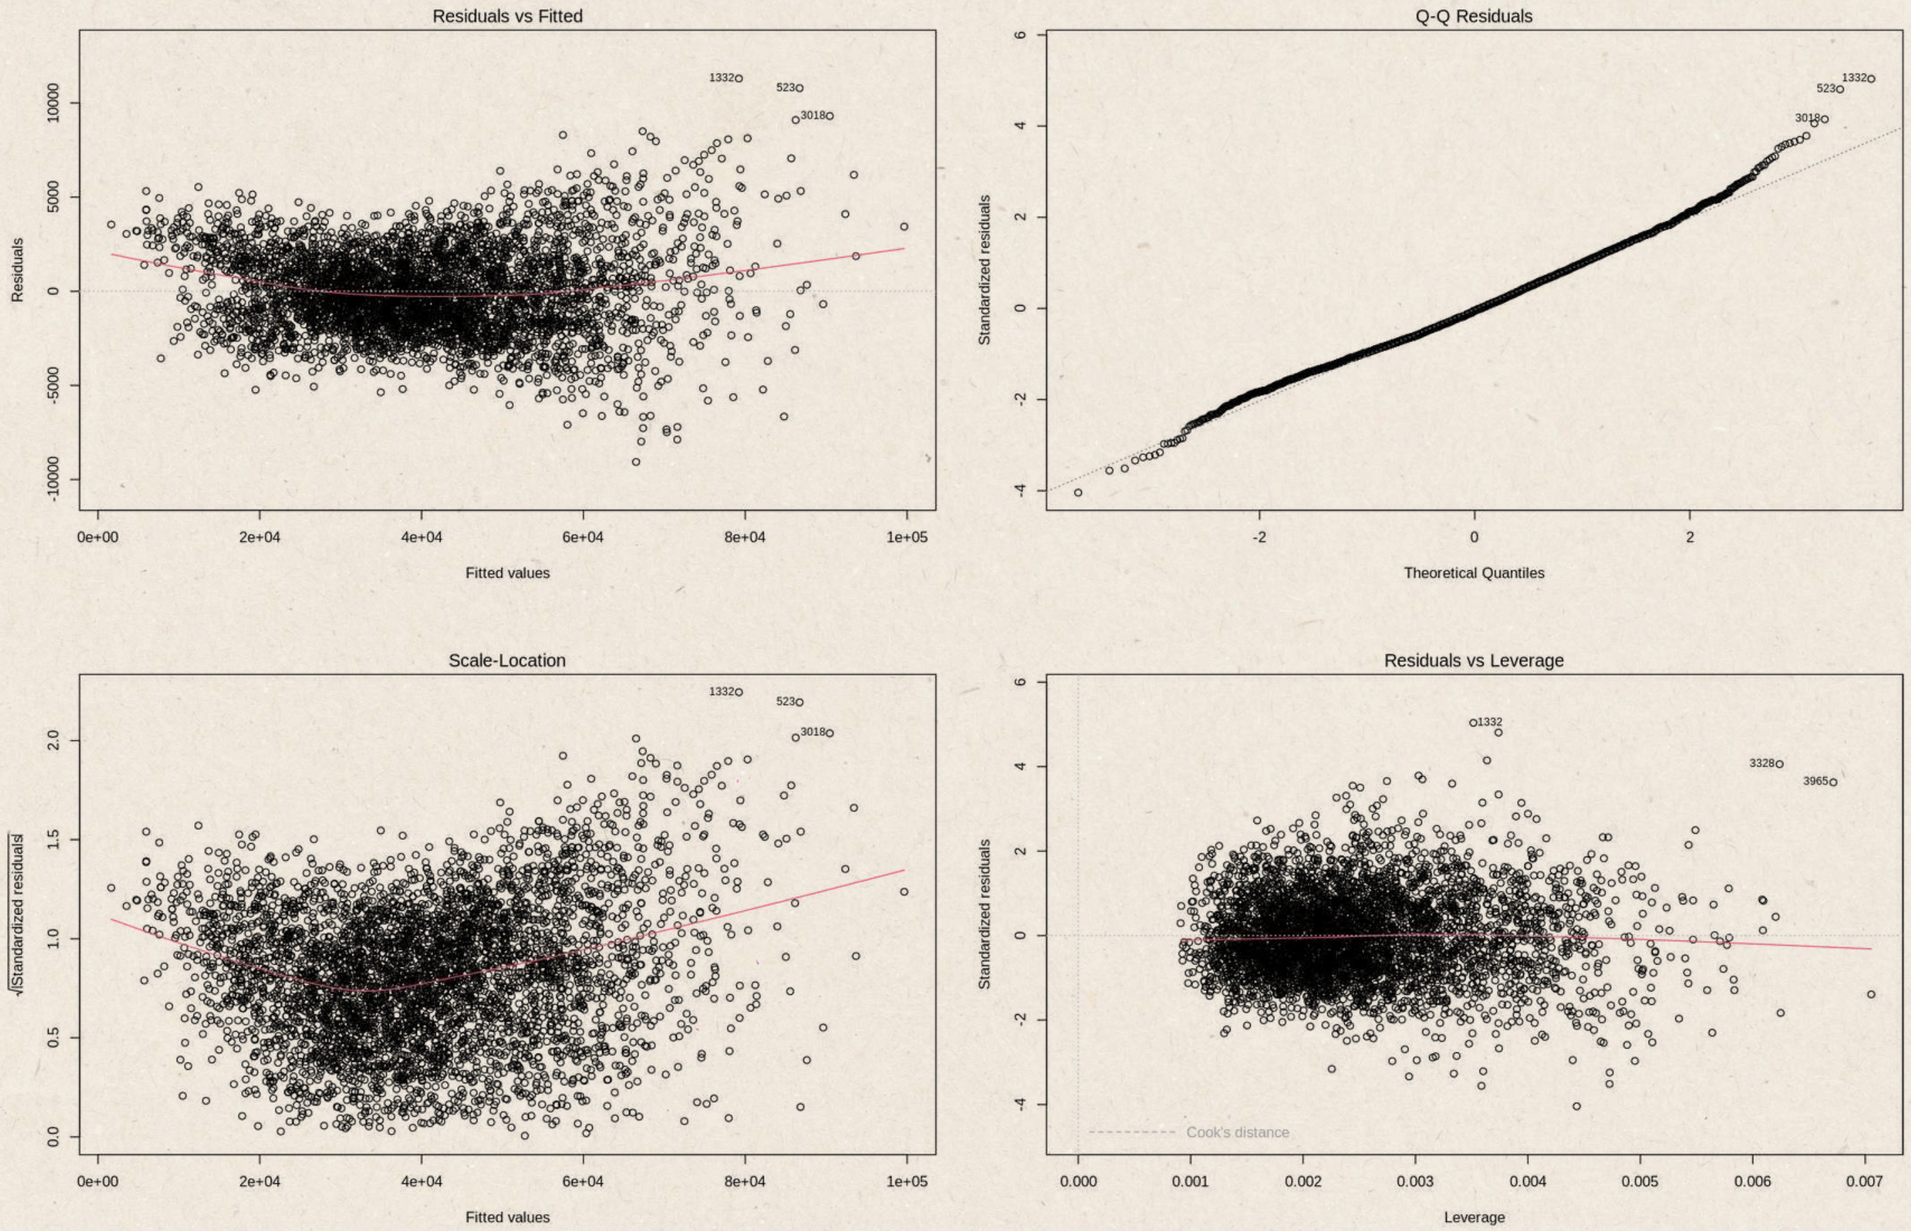

- Os erros não têm média nula, e apresentam um **comportamento não linear**;
- **A variância dos erros não é constante** (denotada σ^2).

Resíduos padronizados do modelo_novo

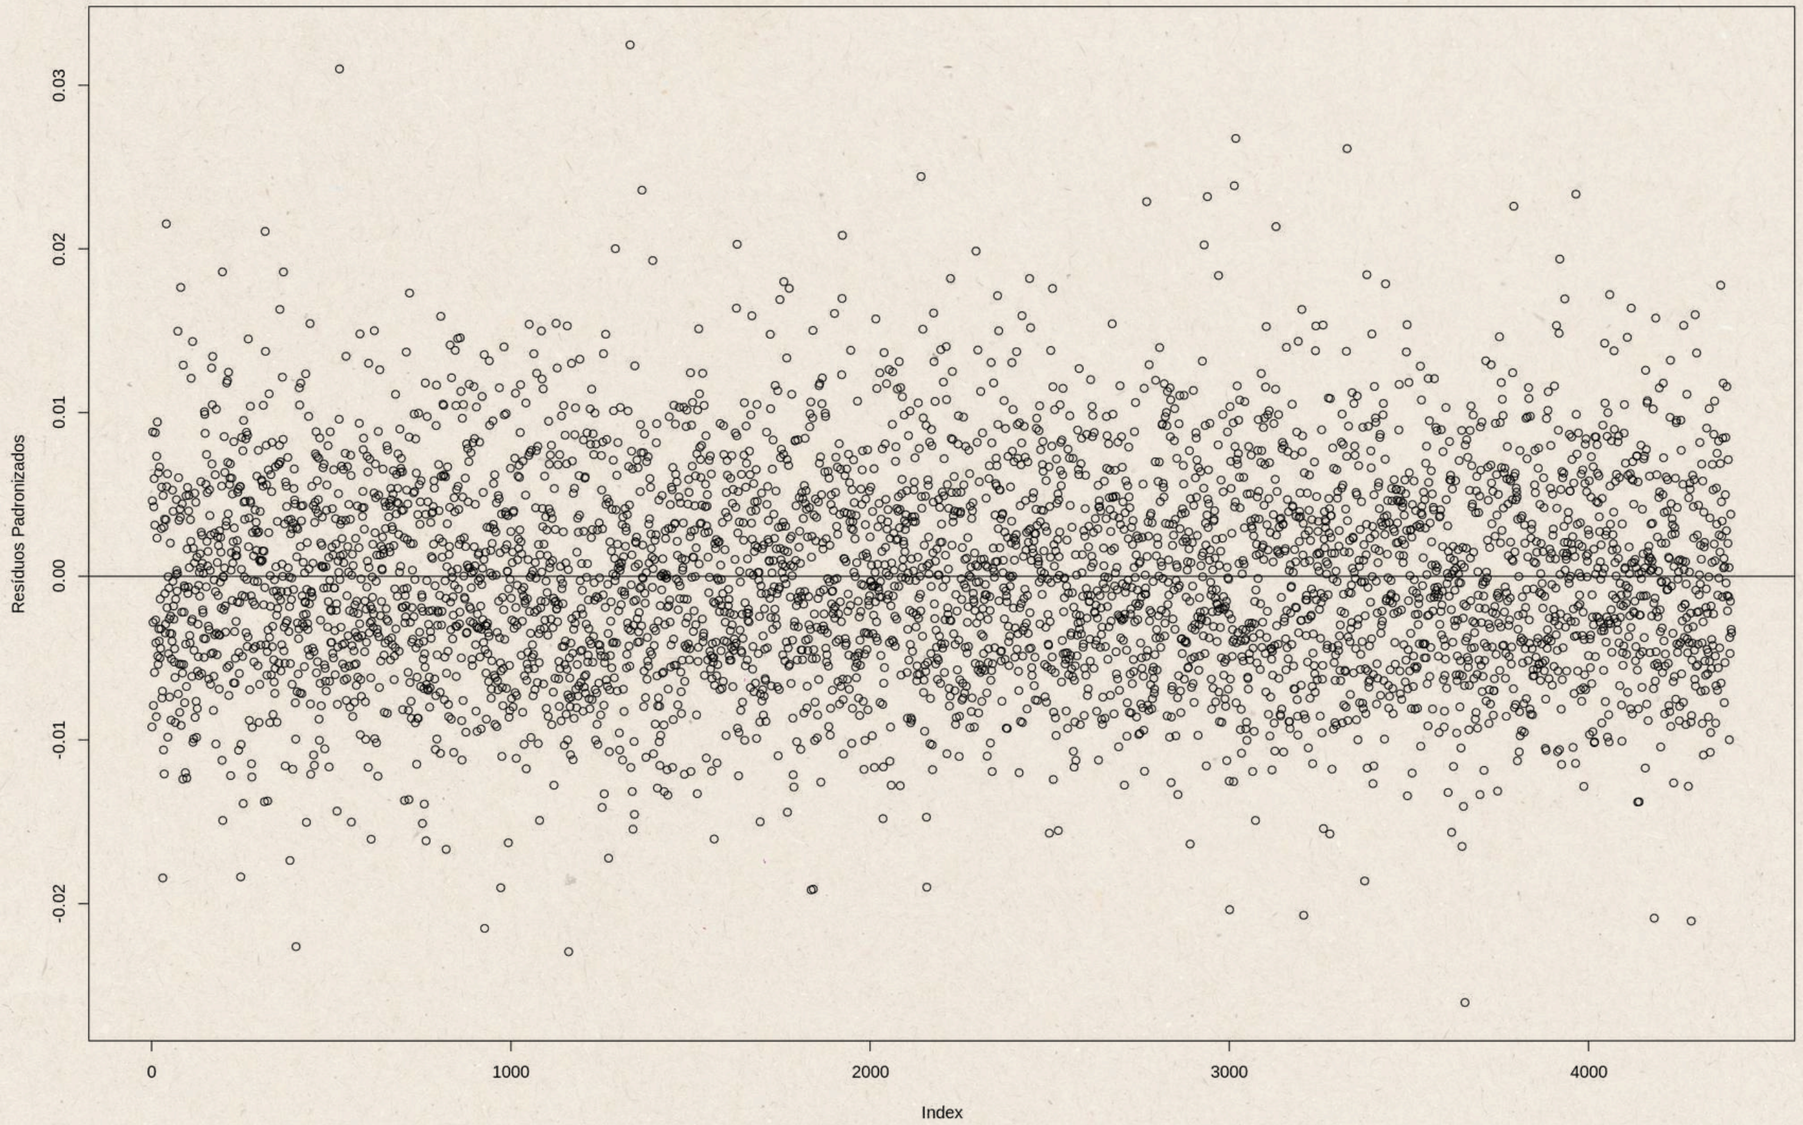

Apesar disso, valores absolutos muito baixos dos resíduos padronizados indicam um bom ajuste do modelo e ausência de outliers.

Resíduos studentizados do modelo_novo

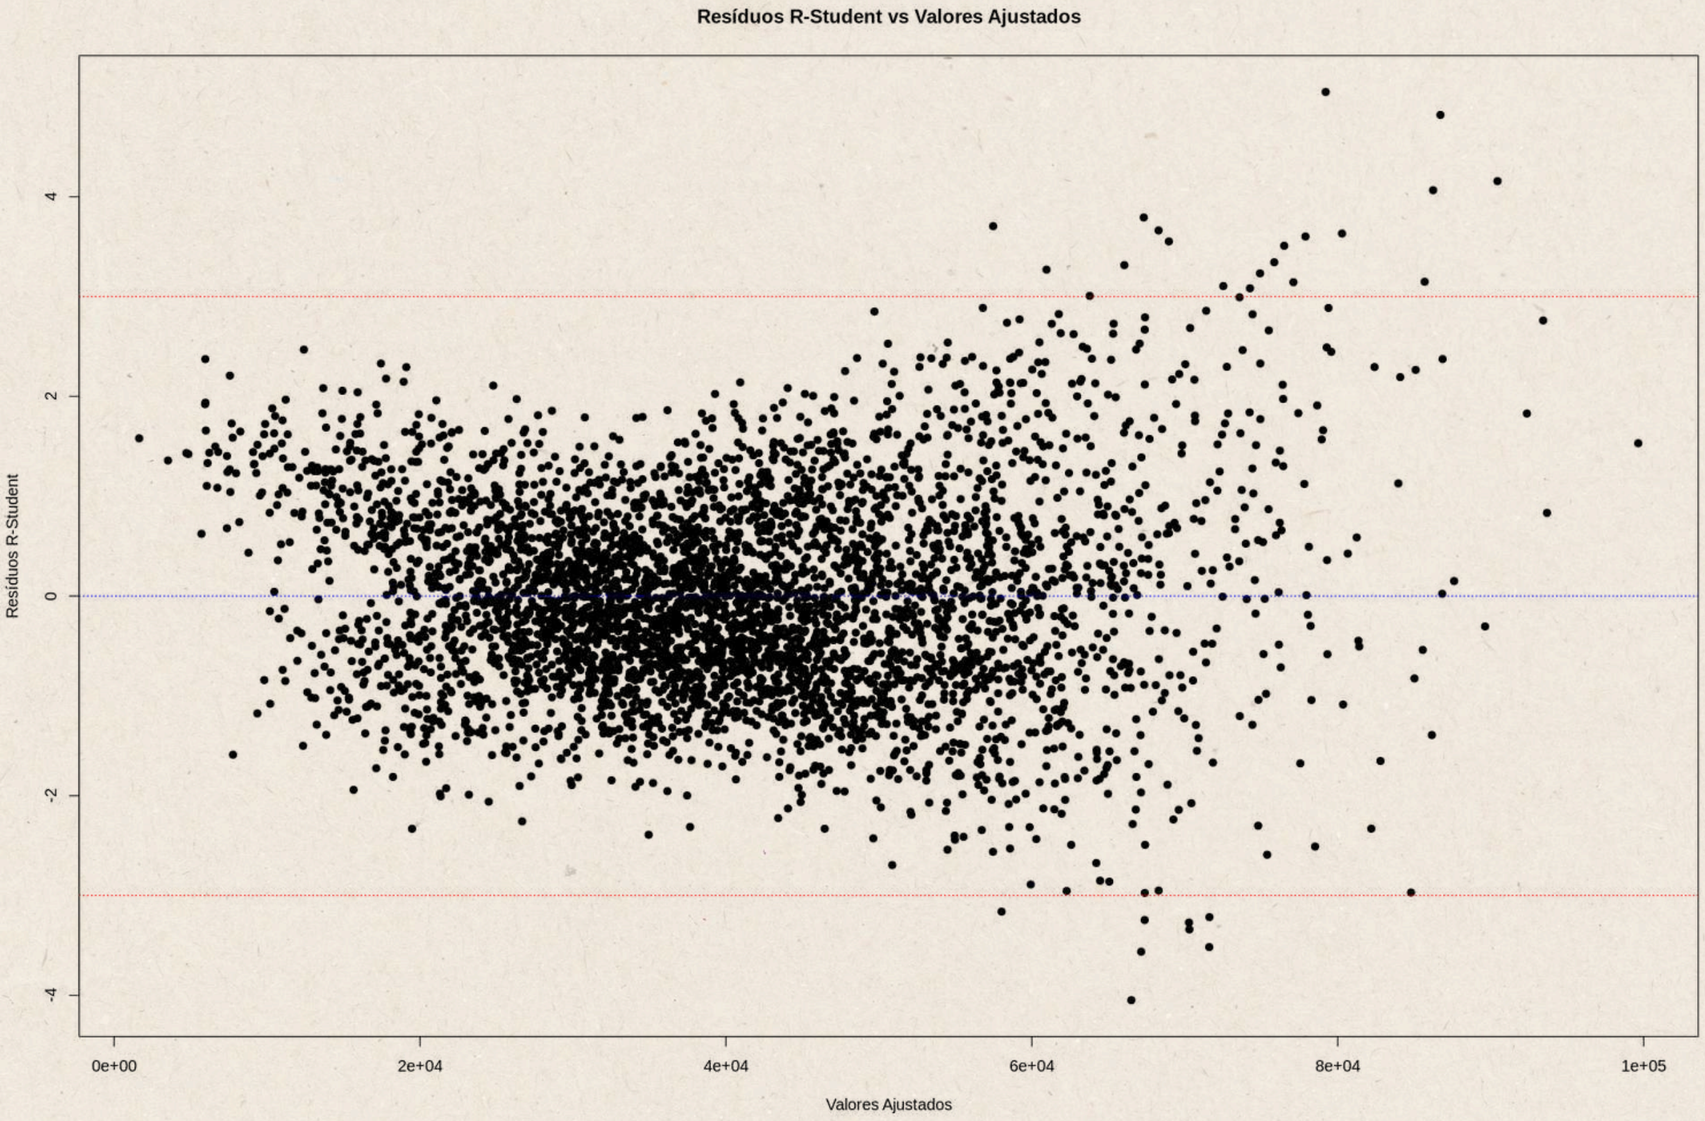

Por outro lado, os resíduos studentizados mostram **a presença de outliers**, assim como sua dispersão indica **heterocedasticidade**.

Modelo_box

```
Call:
lm(formula = age^0.83 ~ uranium_lead_ratio + stratigraphic_layer_depth +
    carbon_14_ratio + radioactive_decay_series + paleomagnetic_data +
    surrounding_rock_type + stratigraphic_position, data = fossil)

Residuals:
     Min       1Q   Median       3Q      Max
-1249.67  -202.22    -2.09   200.49  1117.04

Coefficients:
                                     Estimate Std. Error t value Pr(>|t|)
(Intercept)                        1236.50617   21.19967  58.327  < 2e-16 ***
uranium_lead_ratio                 7175.64798   17.58740 407.999  < 2e-16 ***
stratigraphic_layer_depth             8.37586    0.05244 159.716  < 2e-16 ***
carbon_14_ratio                    1108.65360   19.38633  57.187  < 2e-16 ***
radioactive_decay_series            654.79754   15.70117  41.704  < 2e-16 ***
paleomagnetic_dataReversed polarity 249.60700   10.06052  24.811  < 2e-16 ***
surrounding_rock_typeLimestone      116.54901   15.13456   7.701 1.66e-14 ***
surrounding_rock_typeSandstone       57.54920   14.57132   3.949 7.95e-05 ***
surrounding_rock_typeShale          155.31892   15.19072  10.225  < 2e-16 ***
stratigraphic_positionMiddle       -965.27493   10.22951 -94.362  < 2e-16 ***
stratigraphic_positionTop          -985.78818   15.08460 -65.351  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 299.7 on 4387 degrees of freedom
Multiple R-squared:  0.9793,    Adjusted R-squared:  0.9792
F-statistic: 2.073e+04 on 10 and 4387 DF,  p-value: < 2.2e-16
```

Após aplicação do **método Box-Cox**, obtivemos uma transformação na variável resposta em busca de induzir normalidade nos erros.

Anova do modelo_box

A anova: 8 × 5

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
	<int>	<dbl>	<dbl>	<dbl>	<dbl>
uranium_lead_ratio	1	14819904668	1.481990e+10	165007.19792	0.000000e+00
stratigraphic_layer_depth	1	2302489055	2.302489e+09	25636.28280	0.000000e+00
carbon_14_ratio	1	273335719	2.733357e+08	3043.36378	0.000000e+00
radioactive_decay_series	1	166564303	1.665643e+08	1854.55369	0.000000e+00
paleomagnetic_data	1	57517275	5.751727e+07	640.40657	5.299362e-132
surrounding_rock_type	3	8556003	2.852001e+06	31.75464	2.669363e-20
stratigraphic_position	2	988717792	4.943589e+08	5504.27132	0.000000e+00
Residuals	4387	394012641	8.981369e+04	NA	NA

Identificamos uma **diminuição na Soma dos Quadrados Médios** em relação ao modelo anterior.

Resíduos do modelo_box

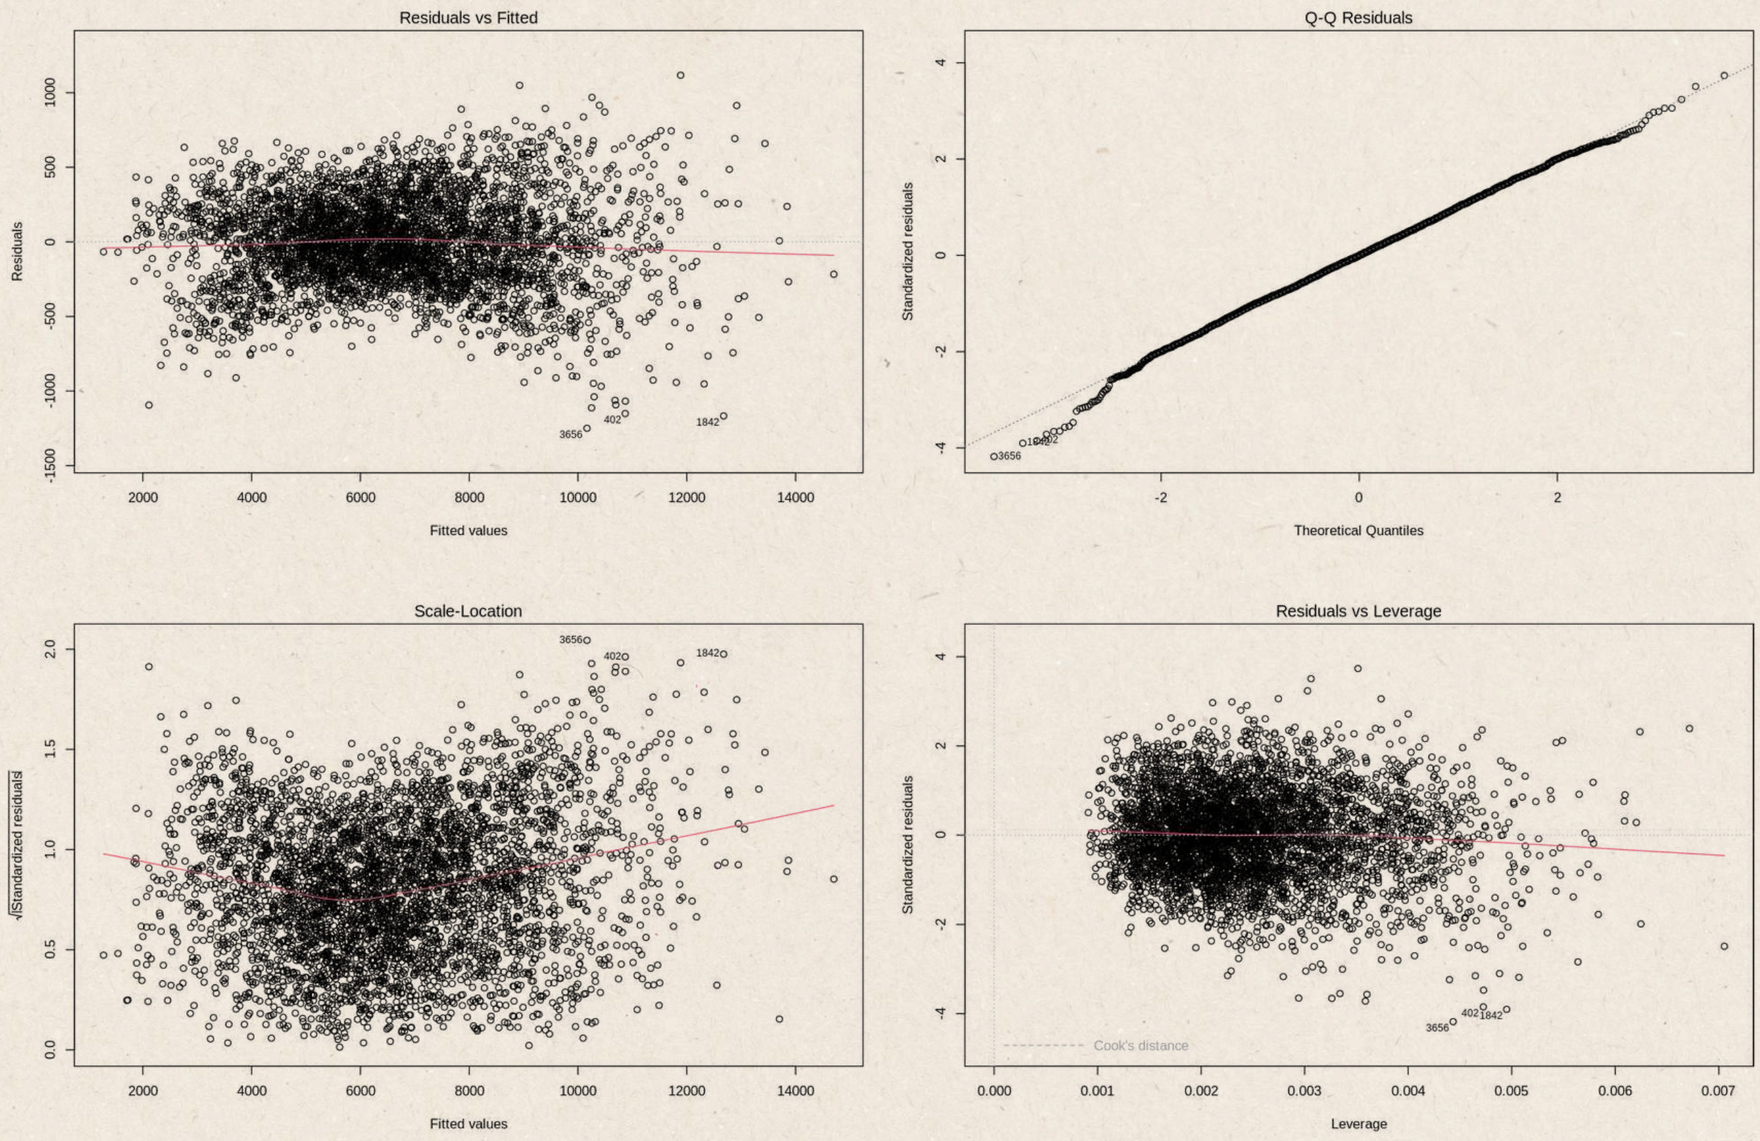

Não houve mudança significativa no comportamento dos resíduos.

Resíduos studentizados do modelo_box

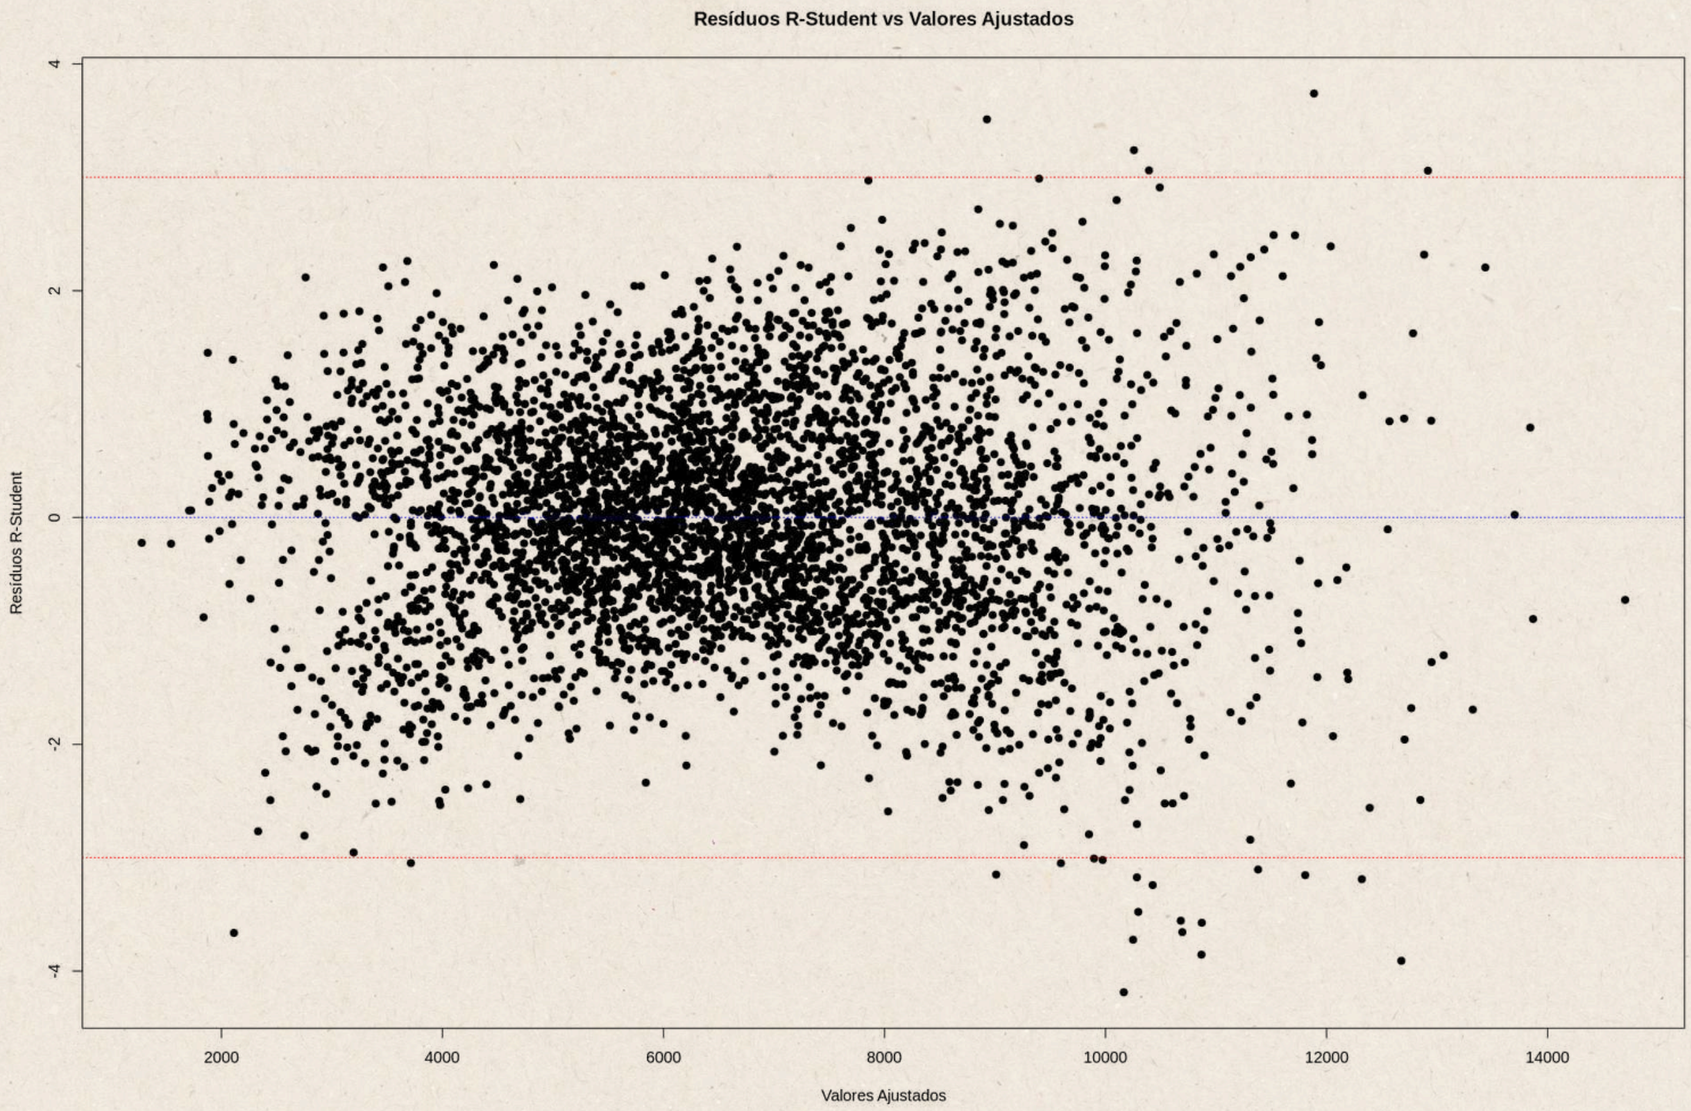

Encontram-se **menos outliers**.

Resíduos padronizado do modelo_box

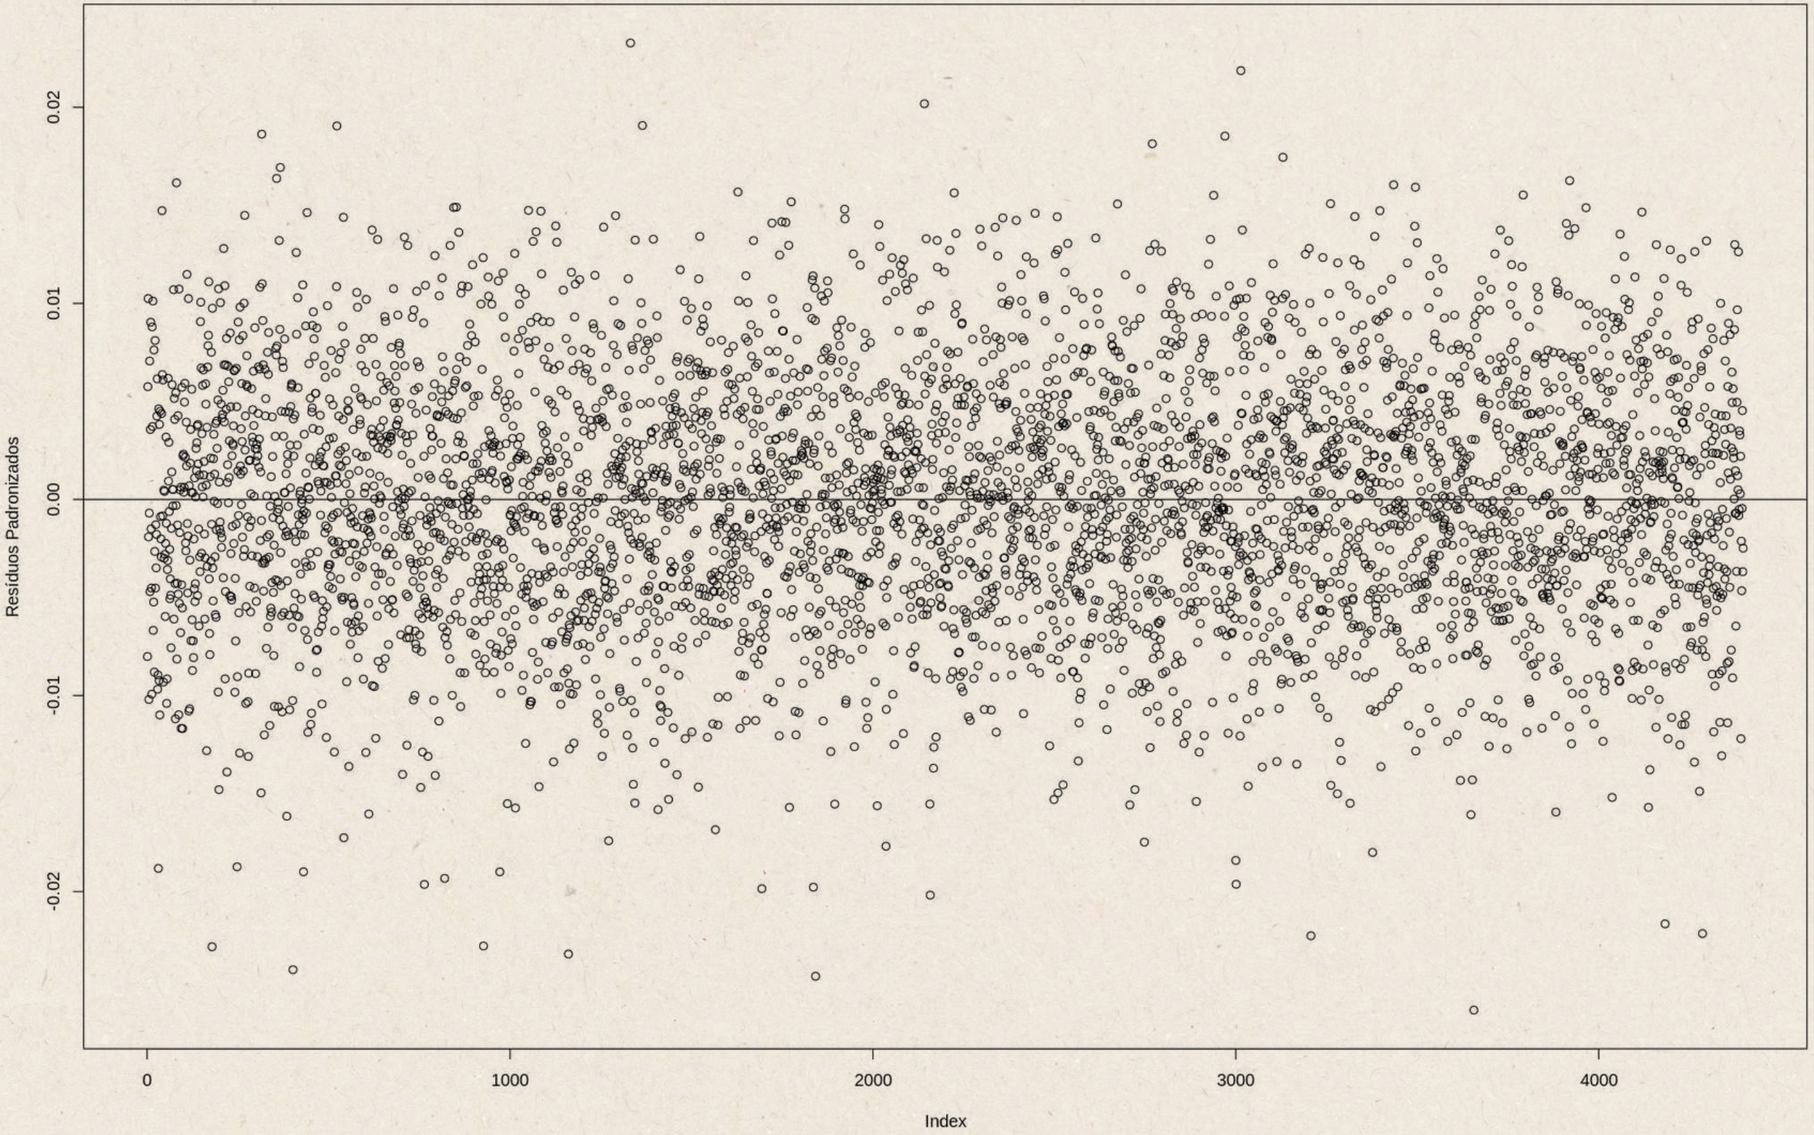

Resíduos padronizados mantiveram-se **baixos**.

Modelo Final

```
Call:
lm(formula = age ~ uranium_lead_ratio + stratigraphic_layer_depth +
    stratigraphic_position, data = fossil)

Residuals:
     Min       1Q   Median       3Q      Max
-14227.7  -2237.2   -113.3   2102.1  16237.7

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
(Intercept)                  8476.4269   146.3936   57.90   <2e-16 ***
uranium_lead_ratio          52603.4119   196.1668  268.16   <2e-16 ***
stratigraphic_layer_depth      60.9111     0.5846  104.19   <2e-16 ***
stratigraphic_positionMiddle -7117.4977   114.0986  -62.38   <2e-16 ***
stratigraphic_positionTop    -7233.5391   168.2298  -43.00   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3344 on 4393 degrees of freedom
Multiple R-squared:  0.9517,    Adjusted R-squared:  0.9516
F-statistic: 2.162e+04 on 4 and 4393 DF,  p-value: < 2.2e-16
```

Neste modelo, reduzimos as variáveis explicativas às **três** que apresentaram maior correlação com a resposta.

Anova do modelo final

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
uranium_lead_ratio	1	792037738786	792037738786	70832.964	0
stratigraphic_layer_depth	1	121176298246	121176298246	10836.954	0
stratigraphic_position	2	53641029521	26820514760	2398.593	0
Residuals	4393	49121504723	11181768	NA	NA

Diminuição do EQM devido à remoção de regressoras.

Resíduos do modelo final

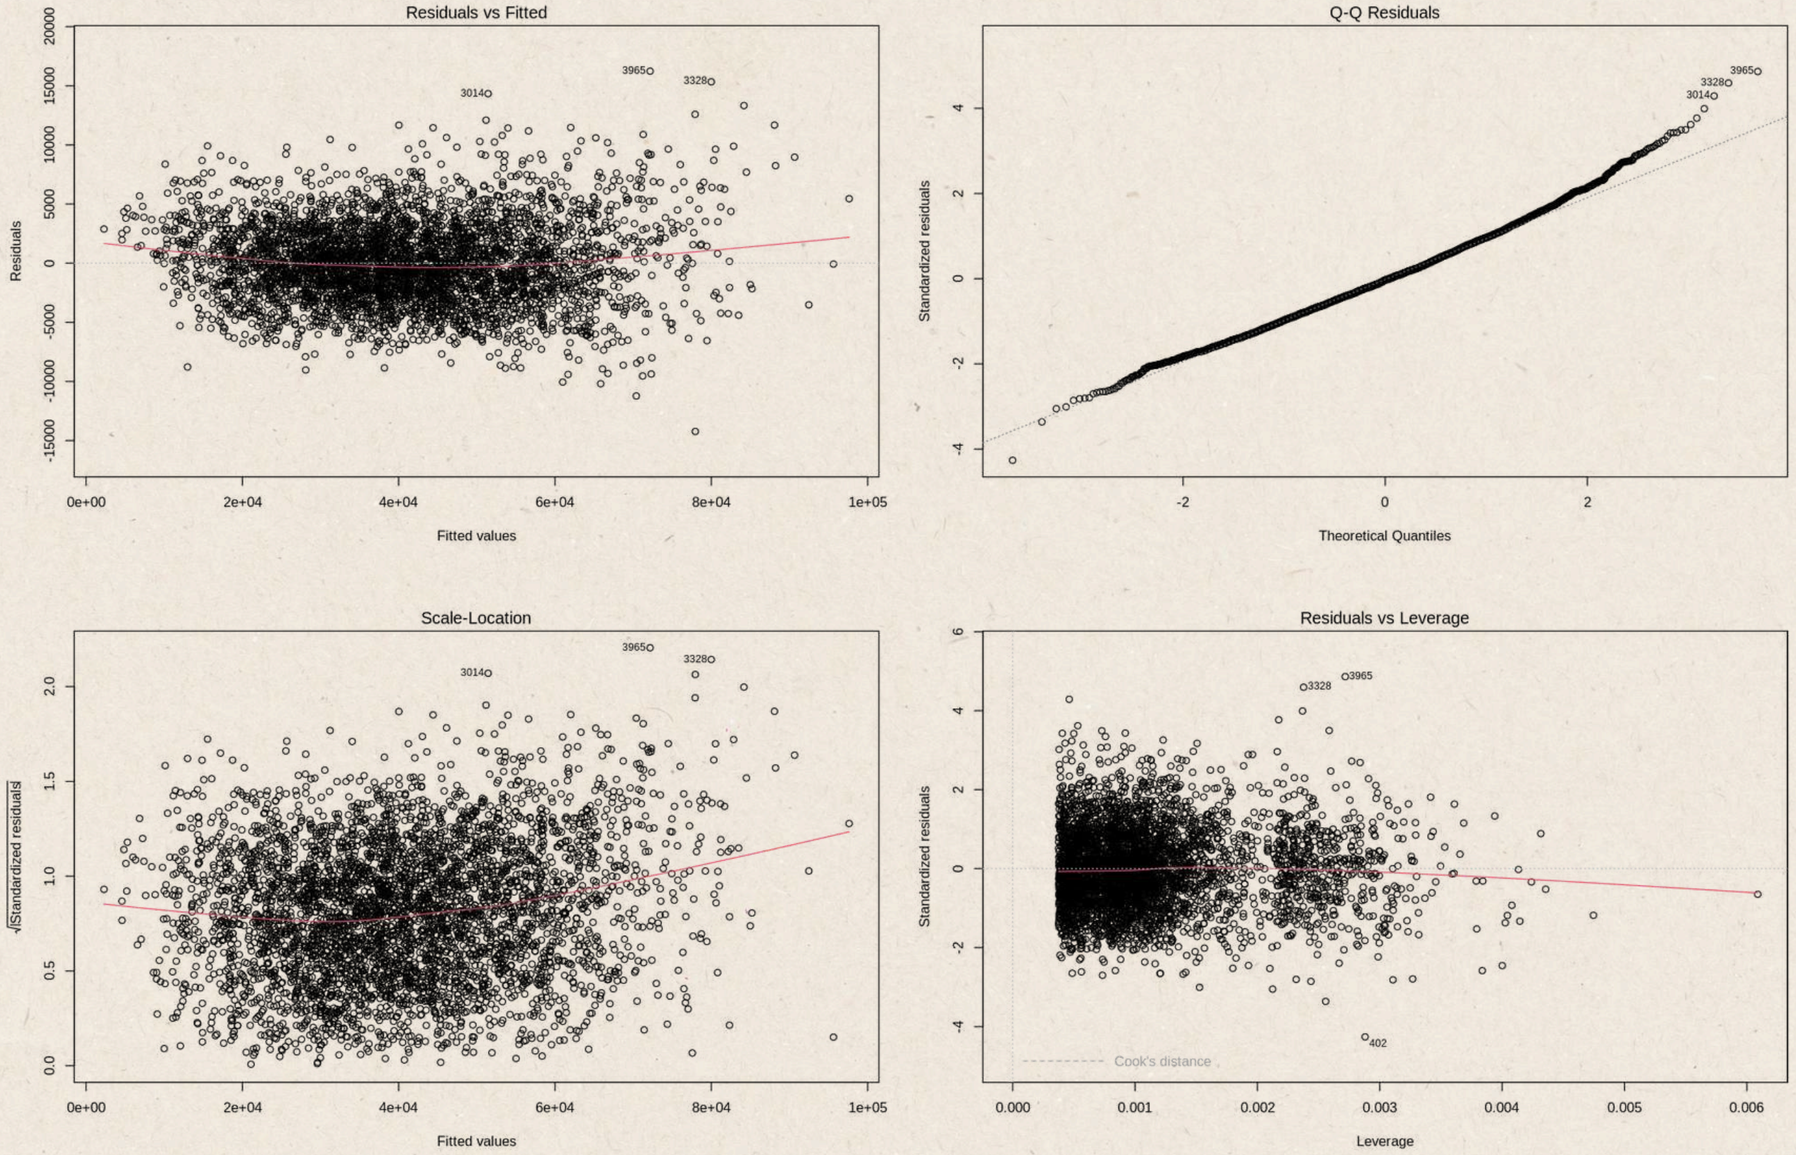

Os resíduos se comportam um pouco melhor quando comparados com os de modelo_novo.

Resíduos padronizados do modelo final

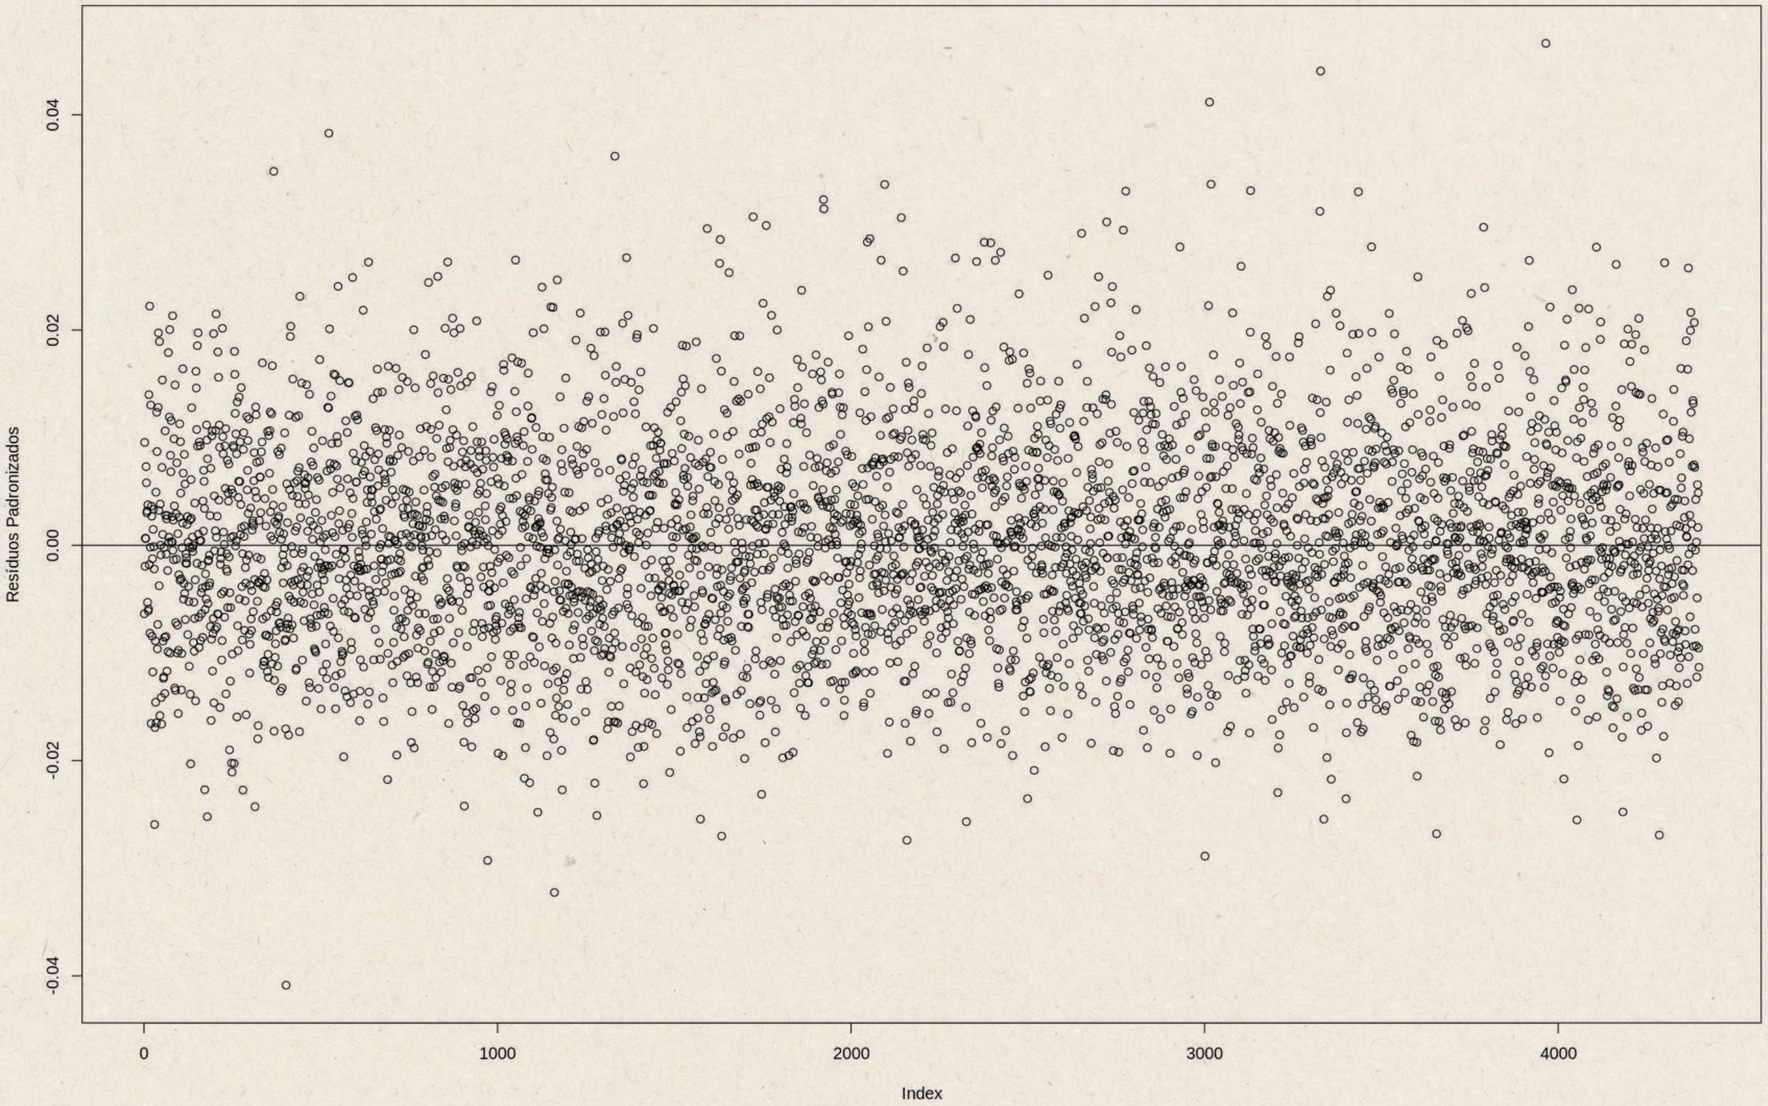

Resíduos padronizados muito baixos.

Resíduos resíduos studentizados do modelo final

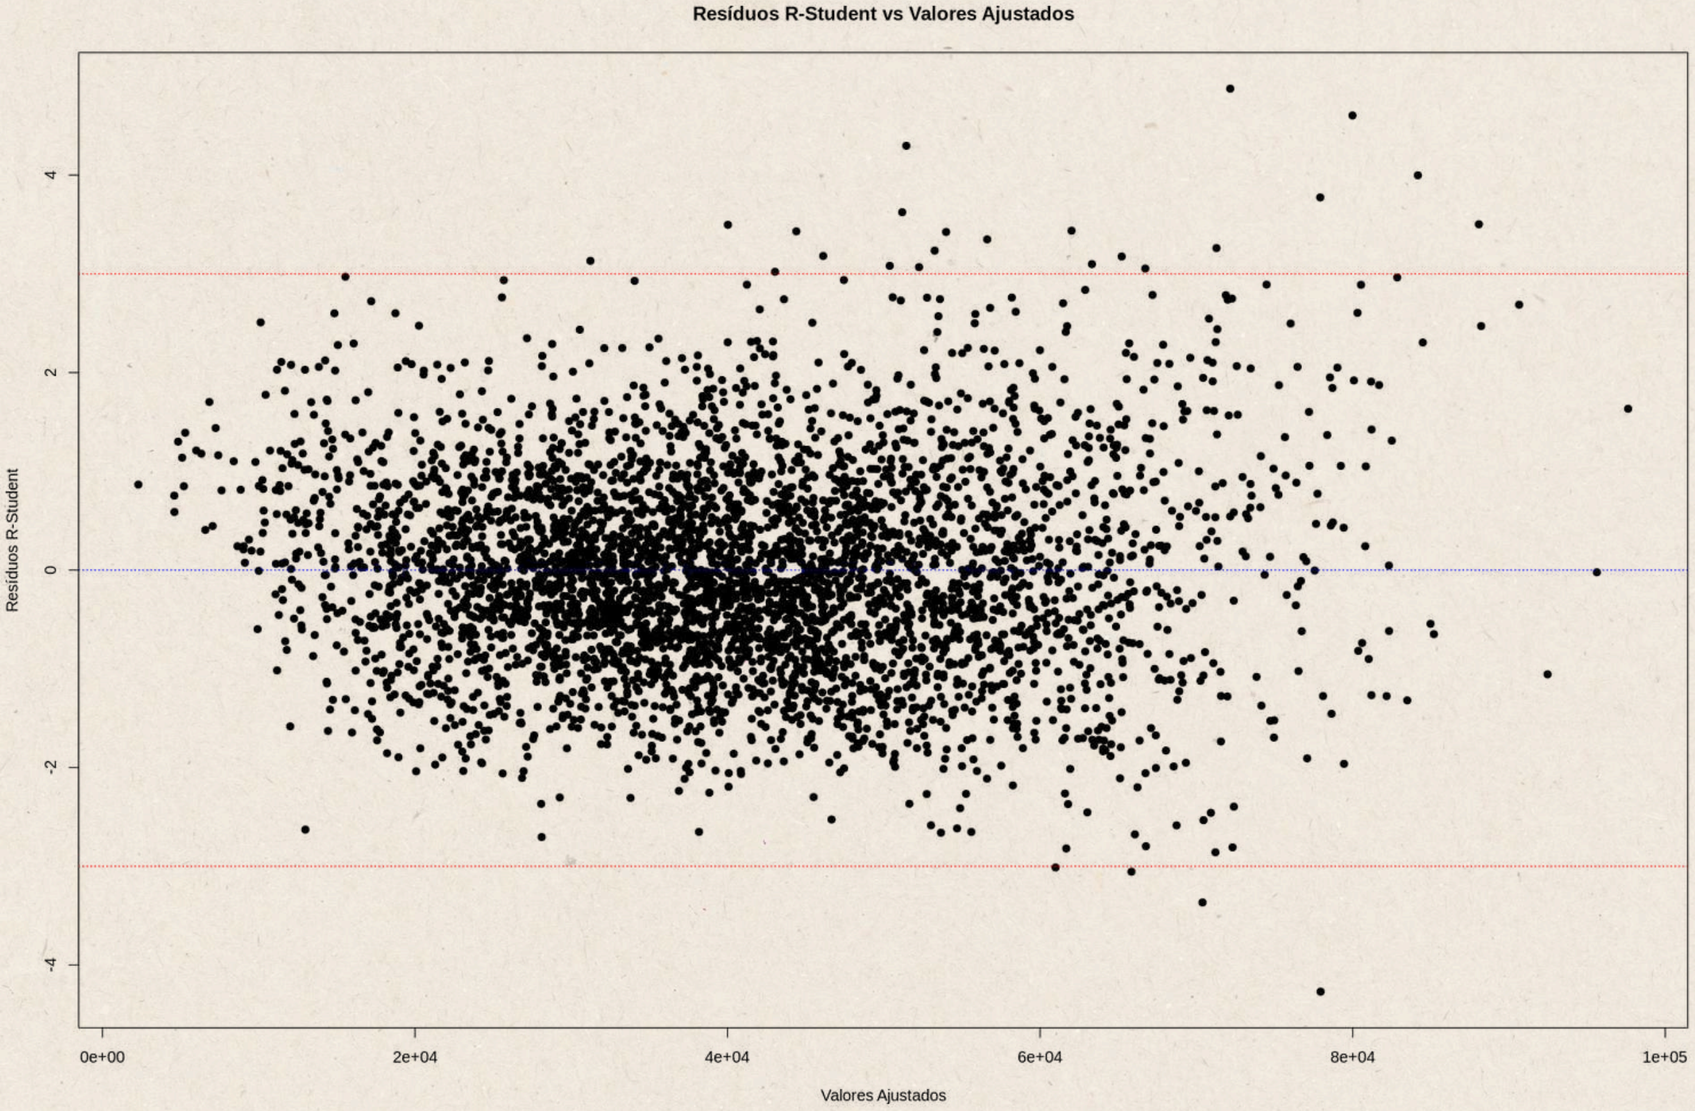

Os resíduos studentizados apontam menos outliers do que em modelo_novo, porém mais do que em modelo_box.

Modelo Final Box-Cox

```
Call:
lm(formula = age^0.83 ~ uranium_lead_ratio + stratigraphic_layer_depth +
    stratigraphic_position, data = fossil)

Residuals:
     Min       1Q   Median       3Q      Max
-2023.96  -297.59   -10.53   295.86  1878.15

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
(Intercept)                 2209.51910   19.84015  111.37   <2e-16 ***
uranium_lead_ratio          7195.66396   26.58573  270.66   <2e-16 ***
stratigraphic_layer_depth      8.39614    0.07923  105.97   <2e-16 ***
stratigraphic_positionMiddle -965.15833   15.46334  -62.42   <2e-16 ***
stratigraphic_positionTop    -981.08004   22.79953  -43.03   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 453.2 on 4393 degrees of freedom
Multiple R-squared:  0.9525,    Adjusted R-squared:  0.9525
F-statistic: 2.204e+04 on 4 and 4393 DF,  p-value: < 2.2e-16
```

Por fim, aplicamos o expoente obtido por Box-Cox ao modelo final e verificamos como se compara aos anteriores.

Anova do modelo final Box-Cox

A anova: 4 x 5

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
	<int>	<dbl>	<dbl>	<dbl>	<dbl>
uranium_lead_ratio	1	14819904668	1.481990e+10	72158.733	0
stratigraphic_layer_depth	1	2302489055	2.302489e+09	11210.915	0
stratigraphic_position	2	986472803	4.932364e+08	2401.589	0
Residuals	4393	902230930	2.053792e+05	NA	NA

Temos redução do EQM devido à presença de menos regressoras.

Resíduos do modelo final Box-Cox

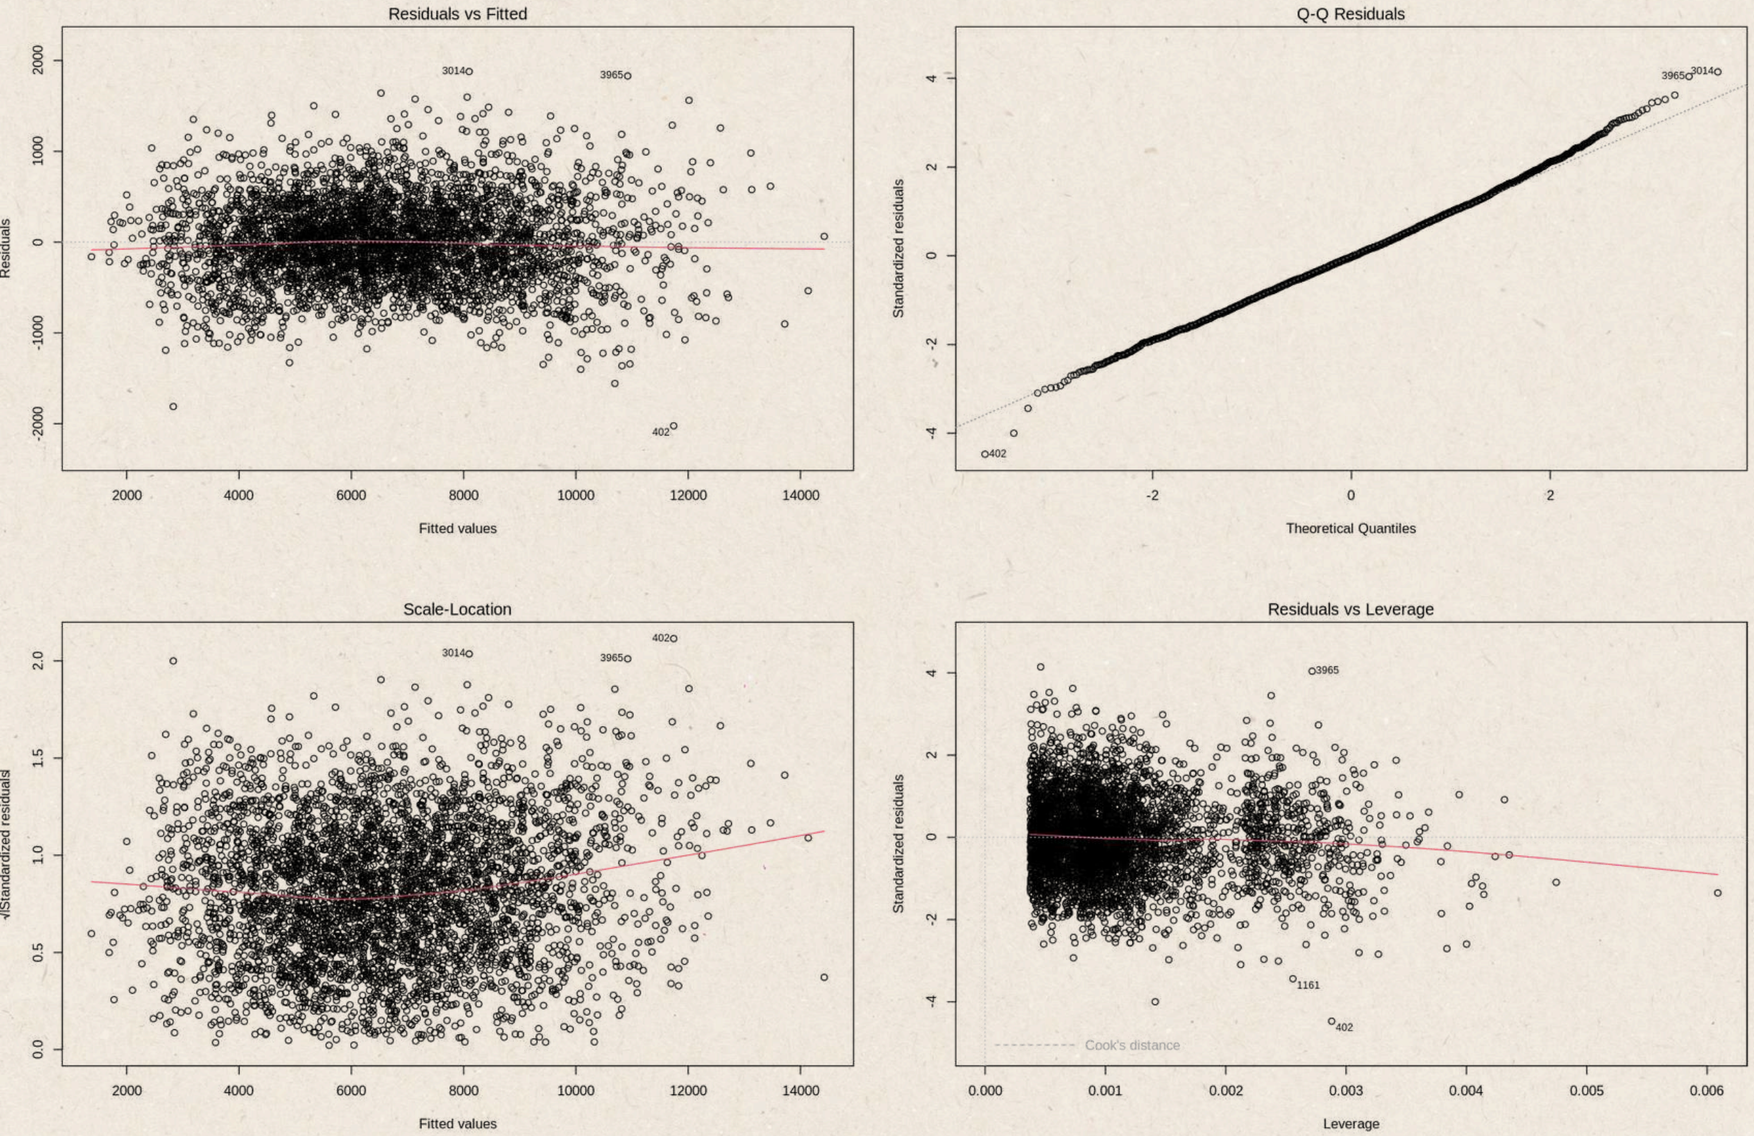

Os resíduos têm um comportamento melhor comparados com os anteriores, e a média se aproximou bastante de zero. Isso significa progresso em induzir a hipótese de normalidade.

Resíduos padronizados do modelo final Box-Cox

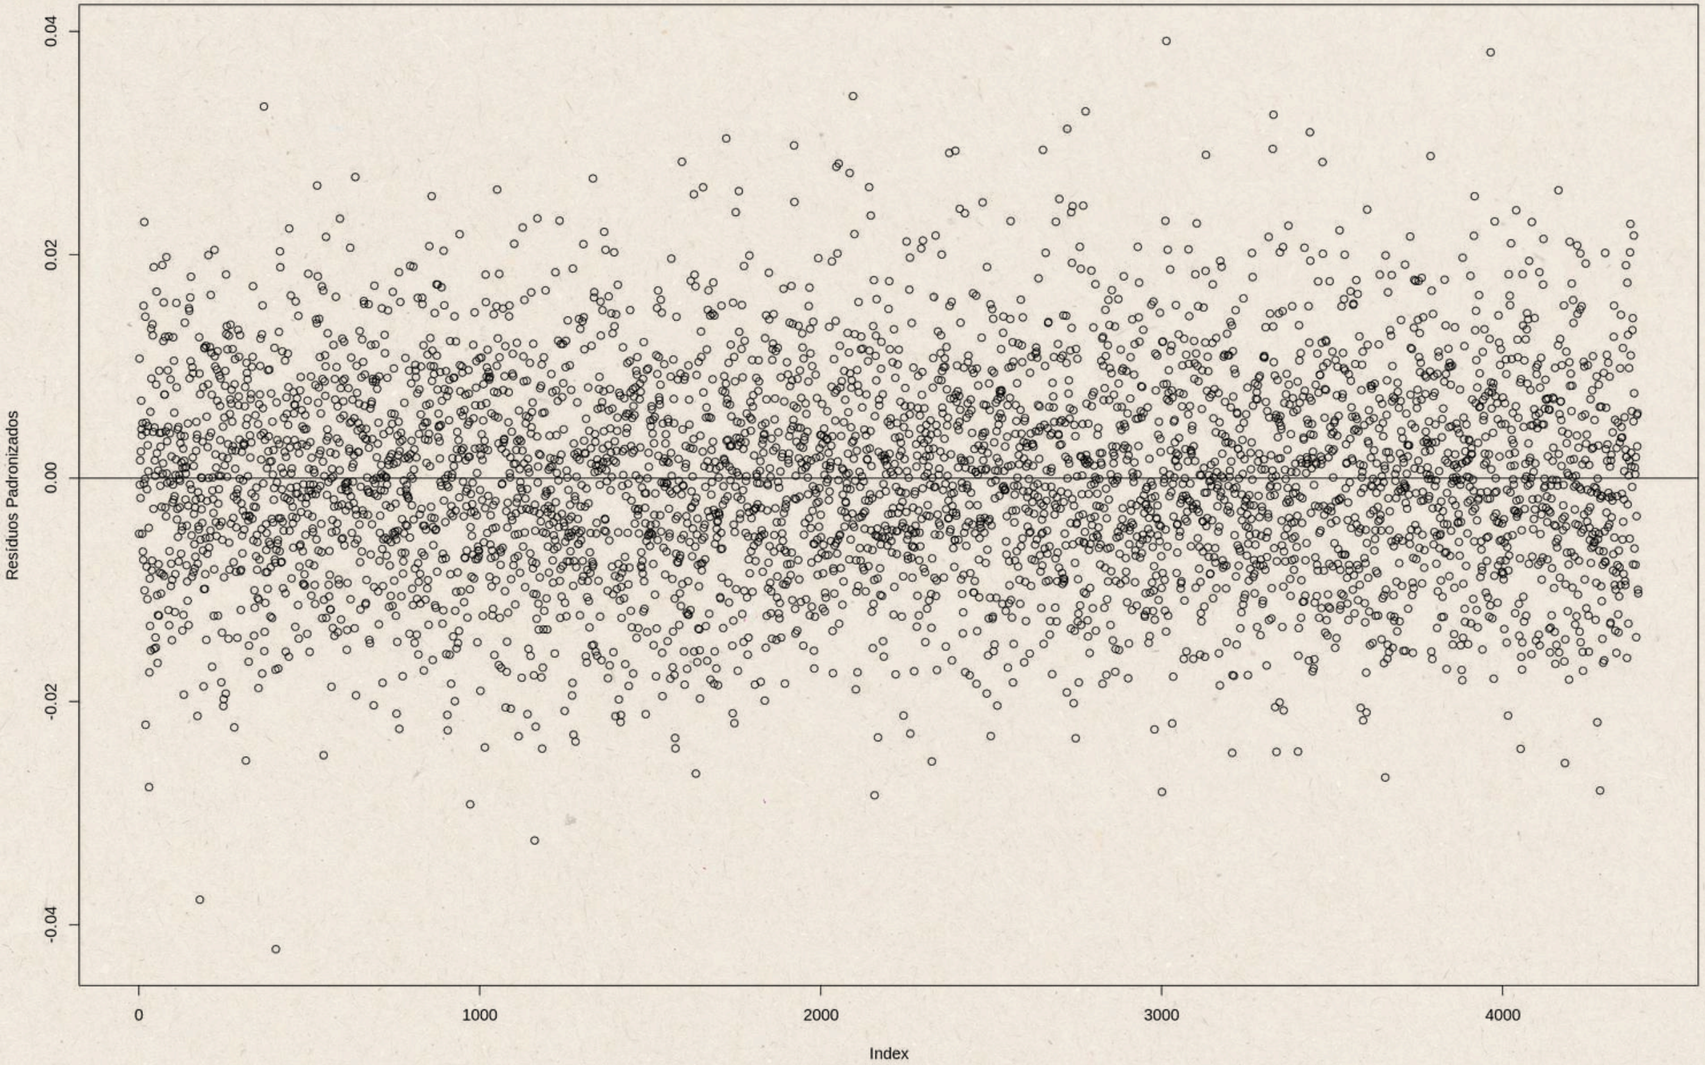

Resíduos padronizados continuam baixos.

Resíduos studentizados do modelo final Box-Cox

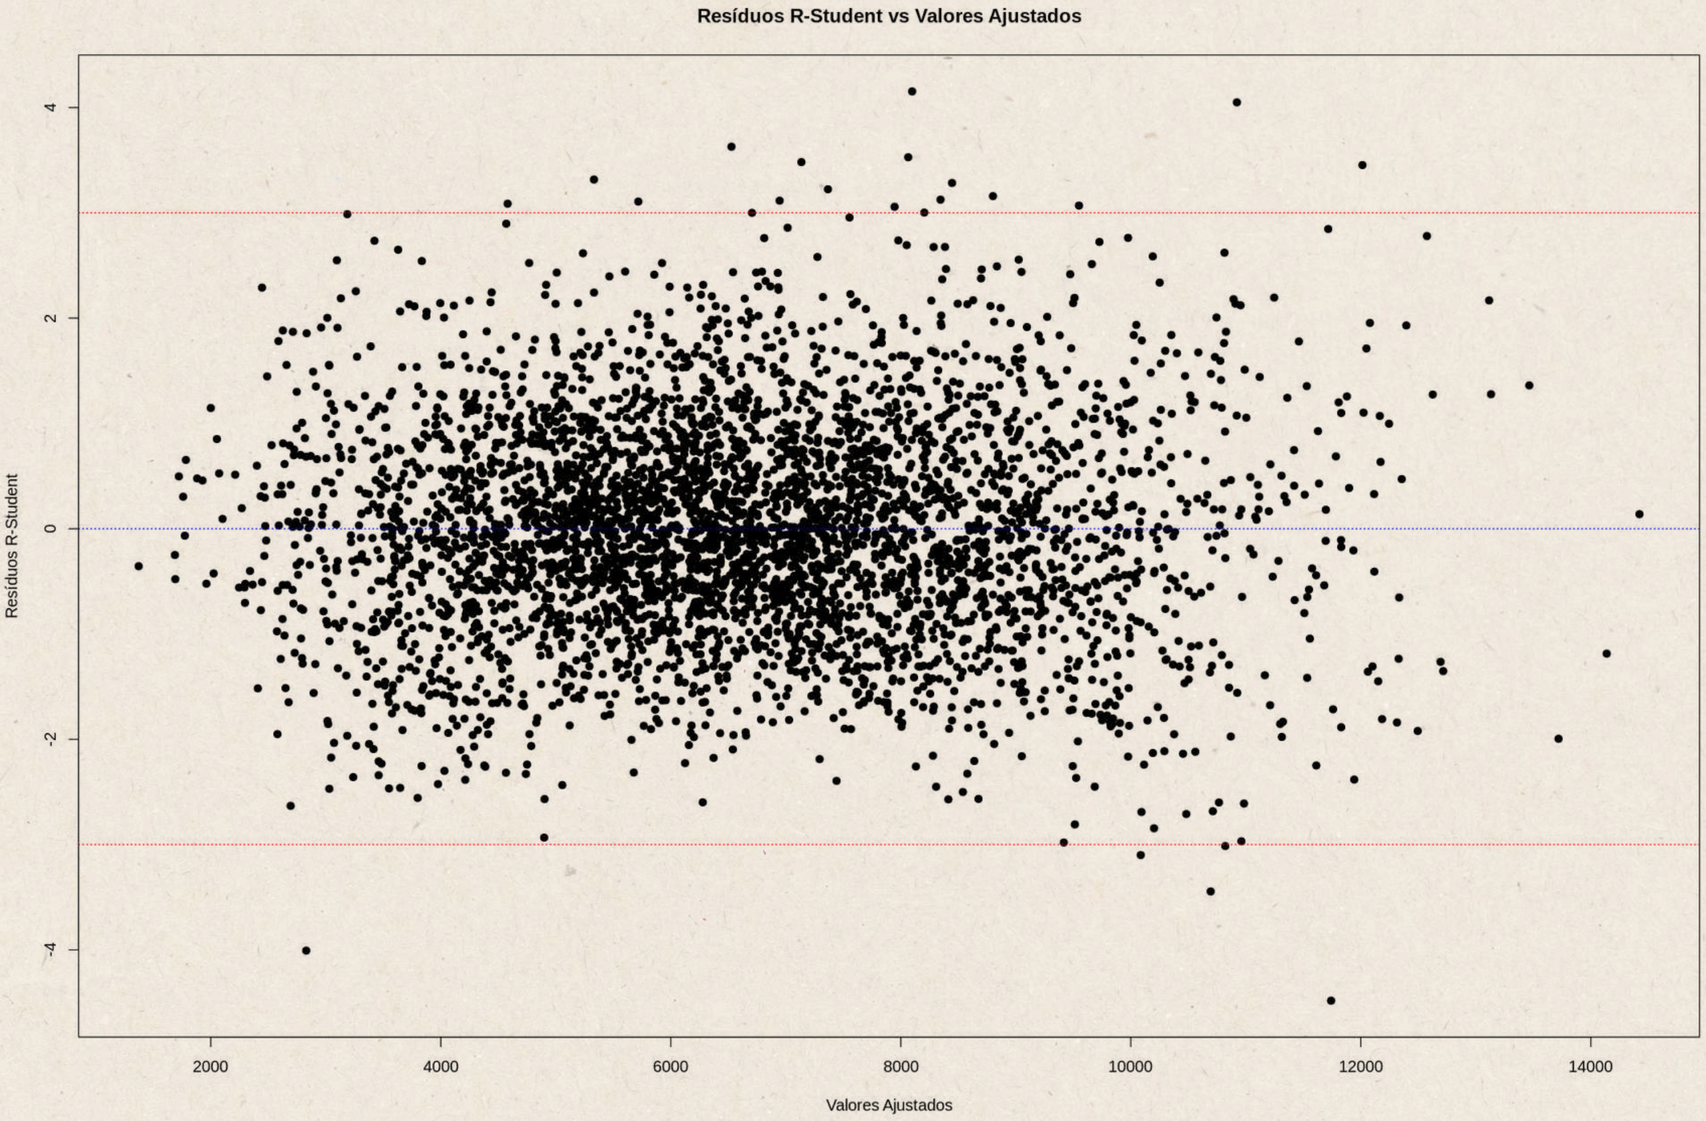

Número de outliers similar ao de modelo_box, embora estejam “invertidos” em relação à quantidade acima de 3 e abaixo de -3.

Regressão Ridge

	x
(Intercept)	2564.287326
uranium_lead_ratio	6607.001519
stratigraphic_layer_depth	7.693745
stratigraphic_positionMiddle	-870.783085

A Regressão Ridge foi aplicada à estrutura preditiva do modelo final Box-Cox. Apesar dos coeficientes estarem distantes daqueles obtidos anteriormente, ainda estão na mesma ordem de grandeza.

Regressão Ridge

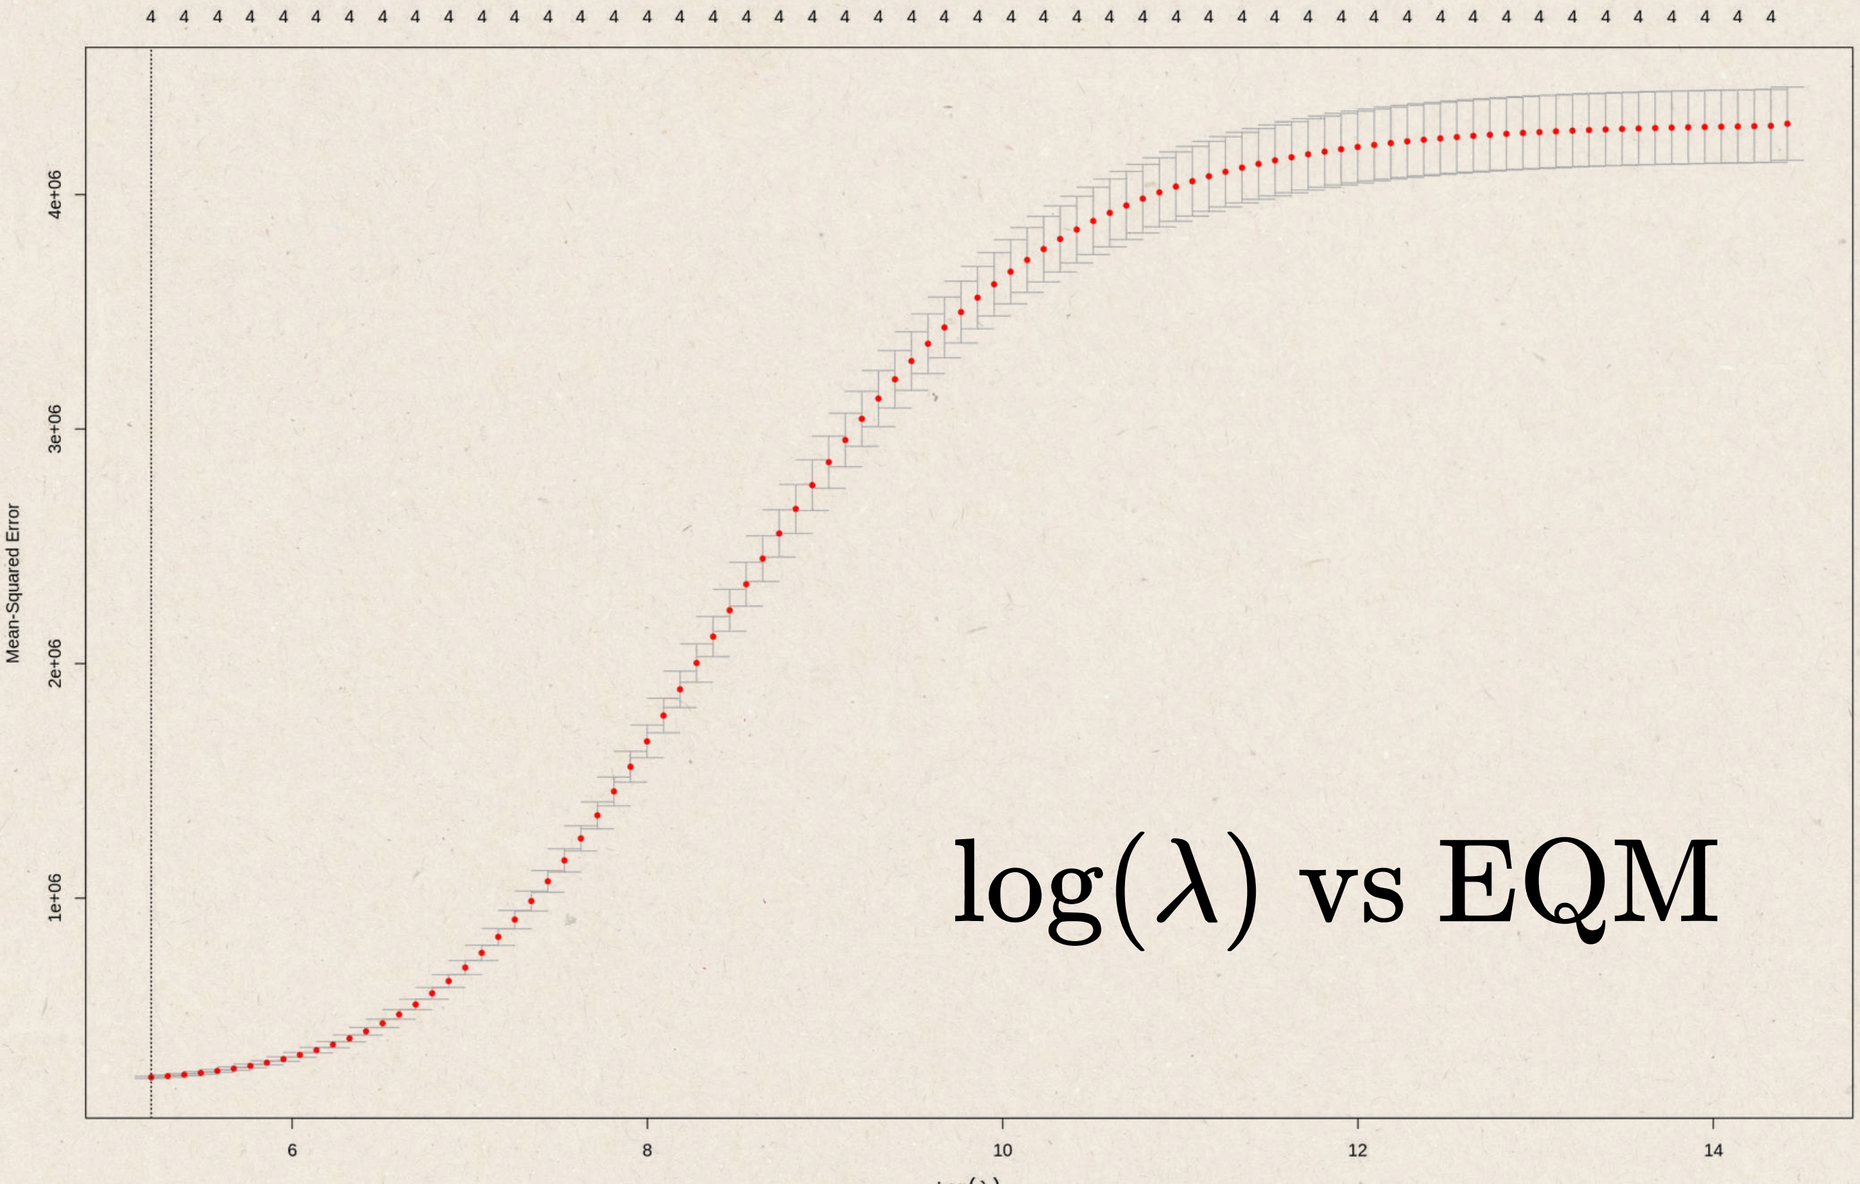

$\log(\lambda)$ vs EQM

Regressão Lasso

	x
(Intercept)	2225.109977
uranium_lead_ratio	7170.462878
stratigraphic_layer_depth	8.322665
stratigraphic_positionMiddle	-947.344363

Com a Regressão Lasso, os coeficientes encontrados são muito mais próximos daqueles em modelo final Box-Cox e nenhuma variável foi descartada.

Regressão Lasso

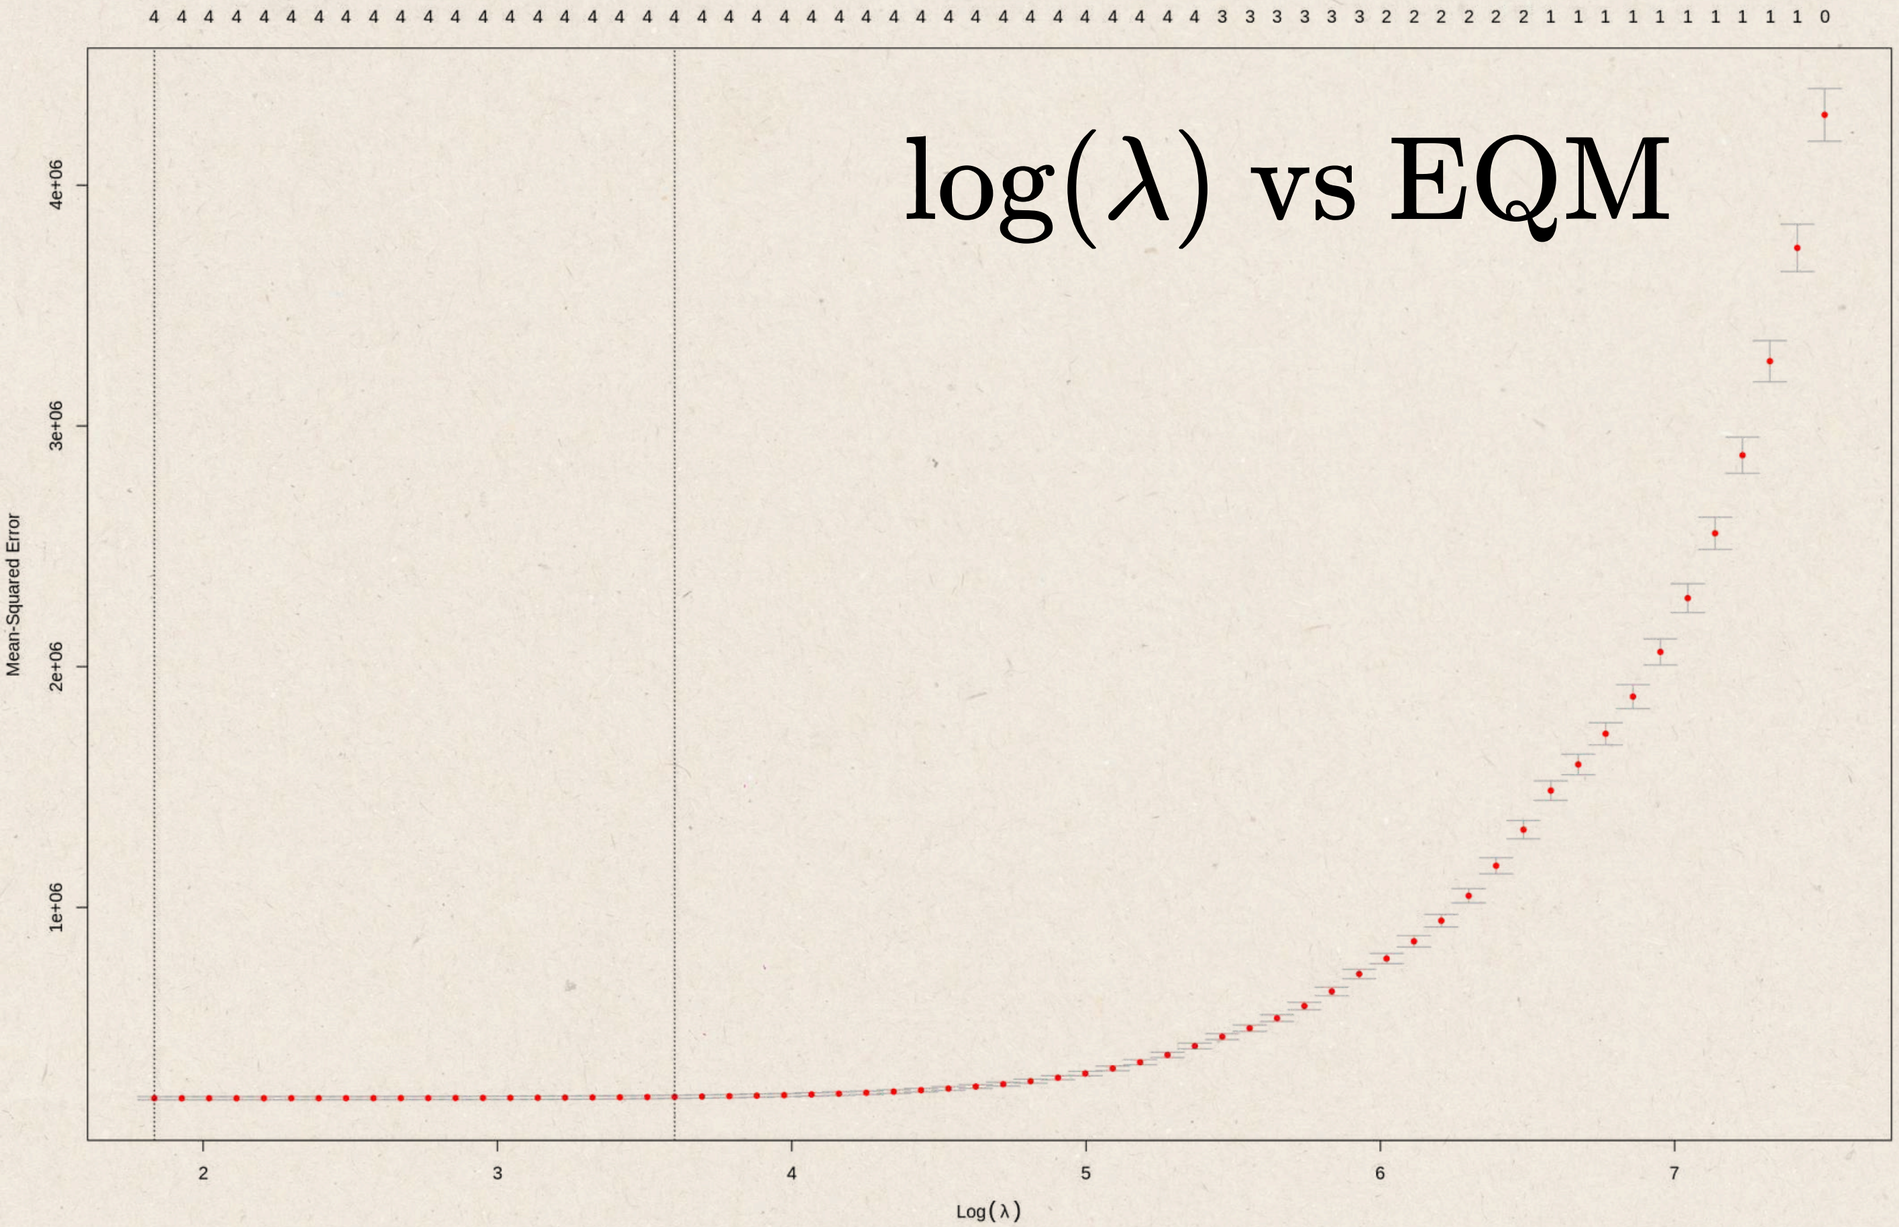

Obrigado!

"Torture os dados, e eles confessarão qualquer coisa."
Ronald Coase