Trabalho de Regressão

Leonardo Pinheiro de Siqueira Alves Rangel
Rhana Gomes de Santana Santos
Stefane Moraes Castoldi

2024-12-07

Introdução

Nosso trabalho tem como objetivo ajustar modelos de regressão linear múltipla a uma base de dados, realizando análises relevantes a partir desses ajustes. Com isso, buscamos avaliar se os modelos construídos são eficazes para prever o comportamento dos dados e responder às questões de interesse.

Seleção da base de dados

A base de dados que utilizamos foi extraída no Kaggle: Predição da Idade de um Fóssil

O conjunto de dados foi criado para fornecer uma base abrangente e realista para treinamento e avaliação de modelos de aprendizado de máquina voltados para a previsão de idades fósseis. Os dados incluem uma variedade de atributos geológicos, químicos e físicos que são significativos no estudo da formação e preservação de fósseis.

Coleta: Os dados iniciais foram obtidos principalmente do PaleoBioDB (O PaleoBioDB é um banco de dados paleontológicos público), com fontes privadas adicionais contribuindo para o conjunto de dados.

Variável Resposta (Y_i): $\dashrightarrow$ **age:** Idade calculada do fóssil, em anos.

Variáveis Regressoras candidatas:

- **Quantitativas:**
  - $\boldsymbol{x_1}$ $\dashrightarrow$ **uranium_lead_ratio**: Proporção de isótopos de urânio para chumbo na amostra do fóssil.
  - $\boldsymbol{x_2}$ $\dashrightarrow$ **carbon_14_ratio**: Proporção de isótopos de carbono-14 presentes na amostra do fóssil.
  - $\boldsymbol{x_3}$ $\dashrightarrow$ **radioactive_decay_series**: Medição da série de decaimento dos isótopos pai para filho.
  - $\boldsymbol{x_4}$ $\dashrightarrow$ **stratigraphic_layer_depth:** Profundidade do fóssil dentro da camada estratigráfica, em metros.
  - $\boldsymbol{x_5}$ $\dashrightarrow$ **isotopic_composition:** Proporção de diferentes isótopos dentro da amostra do fóssil.
  - $\boldsymbol{x_6}$ $\dashrightarrow$ **fossil_size**: Tamanho do fóssil, em centímetros.
  - $\boldsymbol{x_7}$ $\dashrightarrow$ **fossil_weight**: Peso do fóssil, em gramas.
- **Categóricas:**
  - $\boldsymbol{x_8}$ à $\boldsymbol{x_{11}}$ $\dashrightarrow$ **surrounding_rock_type:** Tipo de rocha ao redor do fóssil:
    - $\boldsymbol{x_8} \rightarrow$ Sandstone (arenito)
    - $\boldsymbol{x_9} \rightarrow$ Shale (xisto)
    - $\boldsymbol{x_{10}} \rightarrow$ Limestone (calcário)

    * $\boldsymbol{x_{11}} \rightarrow$ Conglomerate (conglomerado)
  - $\boldsymbol{x_{12}}$ à $\boldsymbol{x_{14}}$ ⇢ **paleomagnetic_data:** Dados de orientação paleomagnética do sítio fóssil:
    * $\boldsymbol{x_{12}} \rightarrow$ Bottom (fundo)
    * $\boldsymbol{x_{13}} \rightarrow$ Middle (meio)
    * $\boldsymbol{x_{14}} \rightarrow$ Top (topo)
  - $\boldsymbol{x_{15}}$ e $\boldsymbol{x_{16}}$ ⇢ **stratigraphic_position:** Posição do fóssil dentro da coluna estratigráfica:
    * $\boldsymbol{x_{15}} \rightarrow$ Normal Polarity (polaridade normal)
    * $\boldsymbol{x_{16}} \rightarrow$ Reversed Polarity (polaridade invertida)
  - $\boldsymbol{x_{17}}$ e $\boldsymbol{x_{18}}$ ⇢ **inclusion_of_others_fossils:** Se há inclusão ou não de outros fósseis
    * $\boldsymbol{x_{17}} \rightarrow$ False (falso)
    * $\boldsymbol{x_{18}} \rightarrow$ True (verdadeiro)

O modelo da Regressão Linear Múltipla será:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_{15} x_{i15} + \beta_{16} x_{i16} + \epsilon_i, \quad i = 1, \ldots, 4398$$

sendo $\epsilon_i \sim \mathcal{N}(0, \delta^2)$.

Análise Exploratória dos dados

Primeiramente, fizemos um mapa de calor da correlação entre as variáveis da nossa base, para identificar possíveis "redundâncias" entre as variáveis candidatas a regressoras, e também identificar se alguma varíavel possui alguma relação linear com a resposta.

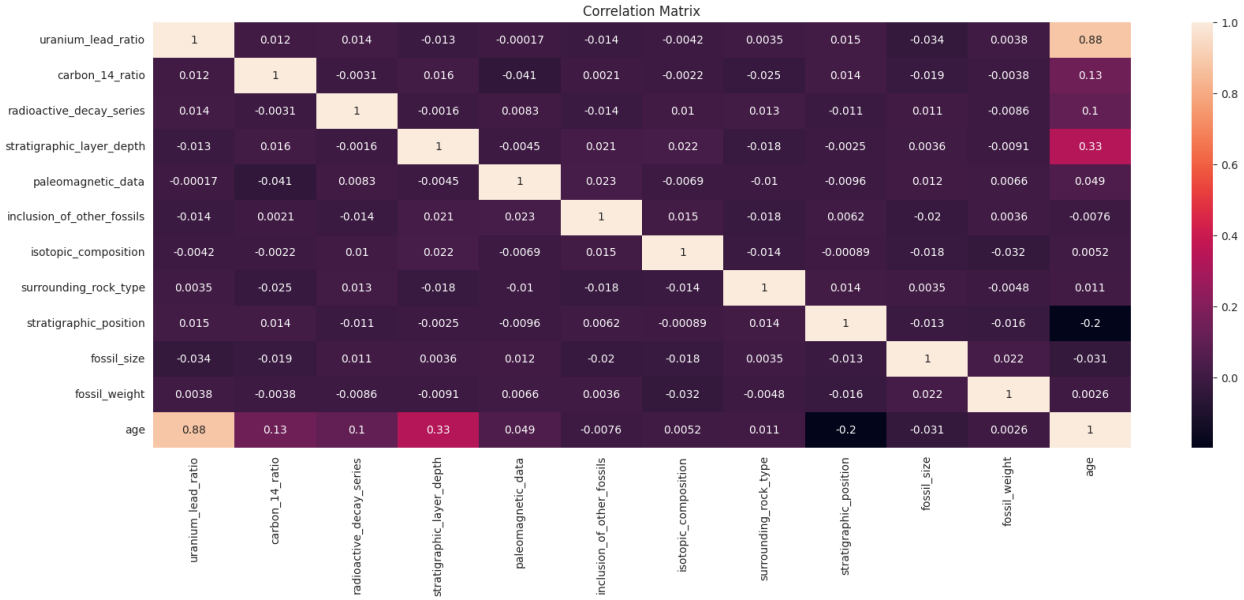

Aqui, podemos perceber que aparentemente não existem problemas de colinearidade entre as possíveis candidatas a regressoras, mas veremos isso melhor mais adiante. Podemos perceber que duas variáveis tem maior correlação com a variável resposta, e portanto podem ser importantes para a explicação do comportamento dos dados, são elas **uranium_lead_ratio** e **stratigraphic_layer_depth**, plotamos o gráfico de pontos de cada uma para analisar melhor:

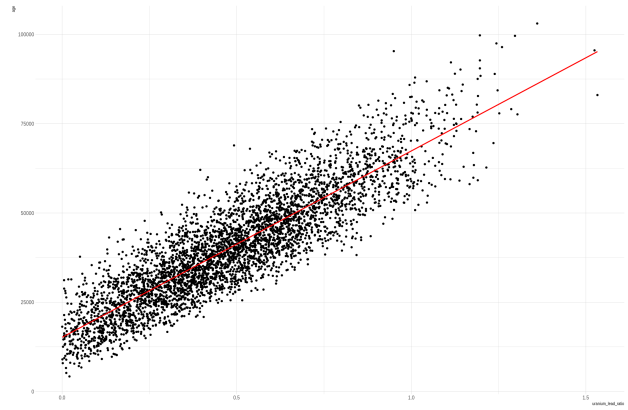

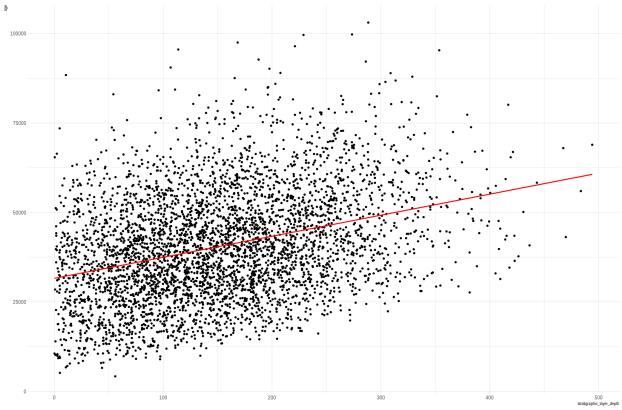

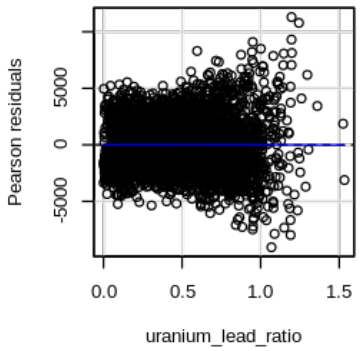
Pearson residuals
uranium_lead_ratio

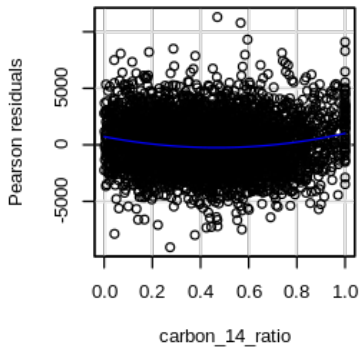
Pearson residuals
carbon_14_ratio

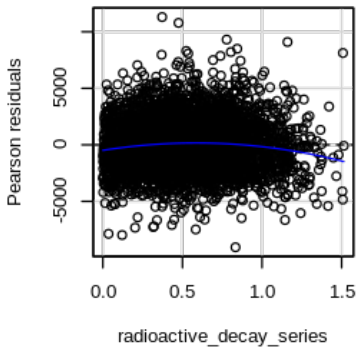
Pearson residuals
radioactive_decay_series

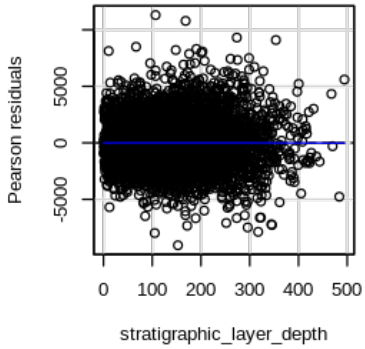
Pearson residuals
stratigraphic_layer_depth

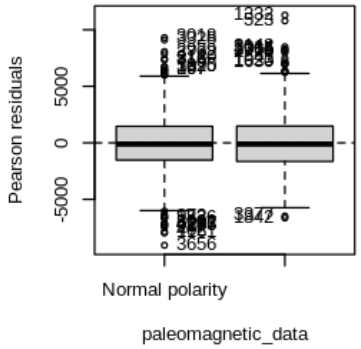
Pearson residuals
Normal polarity
paleomagnetic_data

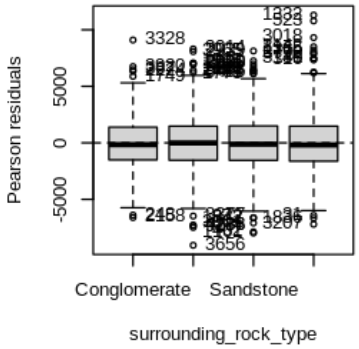
Pearson residuals
Conglomerate
Sandstone
surrounding_rock_type

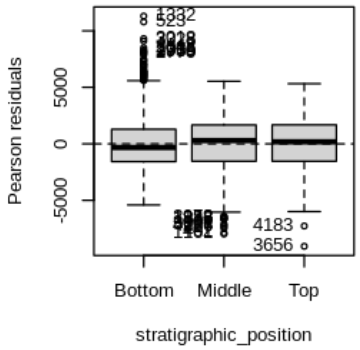
Pearson residuals
Bottom
Middle
Top
stratigraphic_position

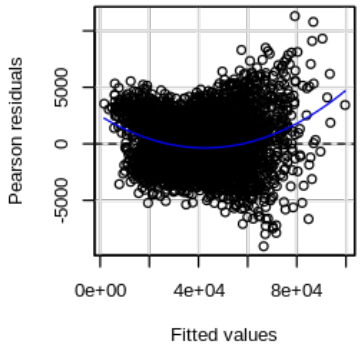
Pearson residuals
Fitted values

Regressão Linear Múltipla

Começamos o ajuste com todas as covariáveis disponíveis na base e com a presença de intercepto:

```
Residuals:
    Min      1Q  Median      3Q     Max 
-9099.3 -1559.4  -122.7  1461.3 11345.2 

Coefficients:
                                     Estimate Std. Error t value Pr(>|t|)    
(Intercept)                         1.452e+03  1.962e+02   7.401 1.61e-13 ***
uranium_lead_ratio                  5.245e+04  1.320e+02 397.233  < 2e-16 ***
stratigraphic_layer_depth           6.078e+01  3.936e-01 154.406  < 2e-16 ***
carbon_14_ratio                     8.041e+03  1.455e+02  55.276  < 2e-16 ***
radioactive_decay_series            4.761e+03  1.178e+02  40.405  < 2e-16 ***
paleomagnetic_dataReversed polarity 1.836e+03  7.551e+01  24.315  < 2e-16 ***
inclusion_of_other_fossilsTrue     -8.018e+01  6.995e+01  -1.146    0.252    
isotopic_composition                2.728e+01  6.514e+01   0.419    0.675    
surrounding_rock_typeLimestone      9.114e+02  1.137e+02   8.019 1.36e-15 ***
surrounding_rock_typeSandstone      4.733e+02  1.094e+02   4.327 1.55e-05 ***
surrounding_rock_typeShale          1.225e+03  1.140e+02  10.749  < 2e-16 ***
stratigraphic_positionMiddle       -7.118e+03  7.676e+01 -92.742  < 2e-16 ***
stratigraphic_positionTop          -7.270e+03  1.132e+02 -64.214  < 2e-16 ***
fossil_size                        -1.089e+00  9.096e-01  -1.197    0.231    
fossil_weight                      -1.981e-02  1.816e-01  -0.109    0.913    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2248 on 4383 degrees of freedom
Multiple R-squared:  0.9782,	Adjusted R-squared:  0.9781 
F-statistic: 1.404e+04 on 14 and 4383 DF,  p-value: < 2.2e-16
```

Consideremos o teste de hipóteses t, sendo:

$$\begin{cases} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{cases}$$

E faremos esse teste para cada $j = 0, 1, ..., 14$. Portanto, não rejeitar H_0 significa não existir relação linear entre a variável resposta e a regressora. Uma forma de analisarmos a significância da regressão é através da estatística T_0. Como estamos trabalhando com um nível de confiança de 95%, caso o p-valor associado a estatística T_0 seja menor do que 0.05, rejeitamos H_0 e concluímos que a regressão é significativa.

Nesse primeiro ajuste, observamos que as covariáveis **inclusion_of_others_fossilsTrue**, **isotopic_composition**, **fossil_size** e **fossil_weight** não parecem ser significativas, pois a estatística T_0 de cada uma delas apresentou um p-valor muito elevado, sendo o menor deles de valor 0.231, o que por si só já é suficiente para nos levar a não rejeição da hipótese de que os coeficientes dessas covariáveis sejam iguais a 0. Por isso, decidimos removê-las do nosso modelo. Todas as outras covariáveis foram significativas, a um nível de confiança de 95%.

Nosso novo modelo ficou:

```
Residuals:
    Min      1Q  Median      3Q     Max 
-9064.6 -1566.6  -113.7  1474.2 11300.0 

Coefficients:
                                     Estimate Std. Error t value Pr(>|t|)    
(Intercept)                          1342.8535   159.0324   8.444  < 2e-16 ***
uranium_lead_ratio                  52458.3179   131.9344 397.609  < 2e-16 ***
stratigraphic_layer_depth              60.7735     0.3934 154.482  < 2e-16 ***
carbon_14_ratio                      8043.6188   145.4294  55.309  < 2e-16 ***
radioactive_decay_series             4761.7407   117.7846  40.428  < 2e-16 ***
paleomagnetic_dataReversed polarity  1832.7397    75.4704  24.284  < 2e-16 ***
surrounding_rock_typeLimestone        909.0806   113.5341   8.007 1.49e-15 ***
surrounding_rock_typeSandstone        471.8090   109.3089   4.316 1.62e-05 ***
surrounding_rock_typeShale           1225.1361   113.9554  10.751  < 2e-16 ***
stratigraphic_positionMiddle        -7119.1139    76.7382 -92.771  < 2e-16 ***
stratigraphic_positionTop           -7268.2720   113.1593 -64.230  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2248 on 4387 degrees of freedom
Multiple R-squared:  0.9782,	Adjusted R-squared:  0.9781 
F-statistic: 1.966e+04 on 10 and 4387 DF,  p-value: < 2.2e-16
```

Fizemos os métodos **Forward Stepwise**, **Backward Elimination** e **Forward Selection + Backward Elimination Selection** e nos 3 casos o melhor modelo ajustado coincidiu com o modelo que ajustamos retirando as varíaveis não significativas. Todas as variáveis permaneceram significativas, a um nível de confiança de 95%.

Estimação intervalar

Aqui temos os intervalos de confiança para os coeficientes do nosso modelo, a um nível de confiança de 95%.

	2.5 %	97.5 %
(Intercept)	1031.06965	1654.63732
uranium_lead_ratio	52199.65980	52716.97603
stratigraphic_layer_depth	60.00224	61.54477
carbon_14_ratio	7758.50378	8328.73377
radioactive_decay_series	4530.82343	4992.65799
paleomagnetic_dataReversed polarity	1684.77952	1980.69987
surrounding_rock_typeLimestone	686.49646	1131.66482
surrounding_rock_typeSandstone	257.50830	686.10960
surrounding_rock_typeShale	1001.72602	1448.54614
stratigraphic_positionMiddle	-7269.55949	-6968.66830
stratigraphic_positionTop	-7490.12142	-7046.42250

Todos os coeficientes estimados para as covariáveis são diferentes de zero a 95% de confiança!

Significância da Regressão

Visando testar a significância da regressão para nosso modelo ajustado, utilizaremos o teste de hipóteses **ANOVA**:

$$\begin{cases} H_0 : \beta_j = 0, \ para\ todo\ j \\ H_1 : pelo\ menos\ um\ \beta_j \ \neq \ 0 \end{cases}$$

Para $j = 0, 1, ..., 10$. Para testar essas hipóteses, nos basearemos no valor da estatística F_0. Pelo summary do R para o modelo ajustado, apresentado anteriormente, verificamos que $F_0 = 1966$ e que o p-valor obtido para essa estatística é extremamente baixo ($<$ 2.2e-16). Dessa forma, rejeitamos H_0 e concluímos que a regressão é significativa.

ANOVA do nosso modelo:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
	<int>	<dbl>	<dbl>	<dbl>	<dbl>
uranium_lead_ratio	1	792037738786	792037738786	156707.67971	0.000000e+00
stratigraphic_layer_depth	1	121176298246	121176298246	23975.19159	0.000000e+00
carbon_14_ratio	1	14366896951	14366896951	2842.54522	0.000000e+00
radioactive_decay_series	1	8819307892	8819307892	1744.93362	2.252939e-321
paleomagnetic_data	1	3100582037	3100582037	613.46195	7.107720e-127
surrounding_rock_type	3	531437335	177145778	35.04897	2.232584e-22
stratigraphic_position	2	53771372707	26885686354	5319.43532	0.000000e+00
Residuals	4387	22172937322	5054237	NA	NA

Agora, para explicarmos a proporção de variabilidade explicada pela regressão, utilizaremos a estatística R^2_{adj} . Quanto mais próximo de 1 esse valor estiver, melhor a variação da variável resposta será explicada pela regressora. No caso do nosso modelo, temos valor de $R^2_{adj} = 0.9781$, então temos 97,81% da variabilidade das idades dos fósseis sendo explicada pela regressão.

Predição de observações futuras

Multicolinearidade

Anteriormente, verificamos que as correlações apresentadas entre as regressoras foram baixas, o que nos forneceu indícios de não haver multicolinearidade. Para confirmar isso, vamos verificar os fatores de inflação de variância (**VIFS**), que não podem ser muito altos.

	GVIF	Df	GVIF^(1/(2*Df))
uranium_lead_ratio	1.001222	1	1.000611
stratigraphic_layer_depth	1.002110	1	1.001055
carbon_14_ratio	1.003491	1	1.001744
radioactive_decay_series	1.000573	1	1.000286
paleomagnetic_data	1.002422	1	1.001210
surrounding_rock_type	1.004830	3	1.000803
stratigraphic_position	1.002276	2	1.000568

Como podemos ver na coluna **GVIF**, pelos valores dos vifs indicados acima, todos próximos de 1, conseguimos concluir que não há multicolinearidade entre as regressoras no nosso modelo.

Análise de Resíduos

Verificaremos agora, a partir da análise de resíduos, possíveis violações das suposições do modelo de regressão linear normal.

Plotamos um gráfico de Resíduos vs Valores Ajustados:

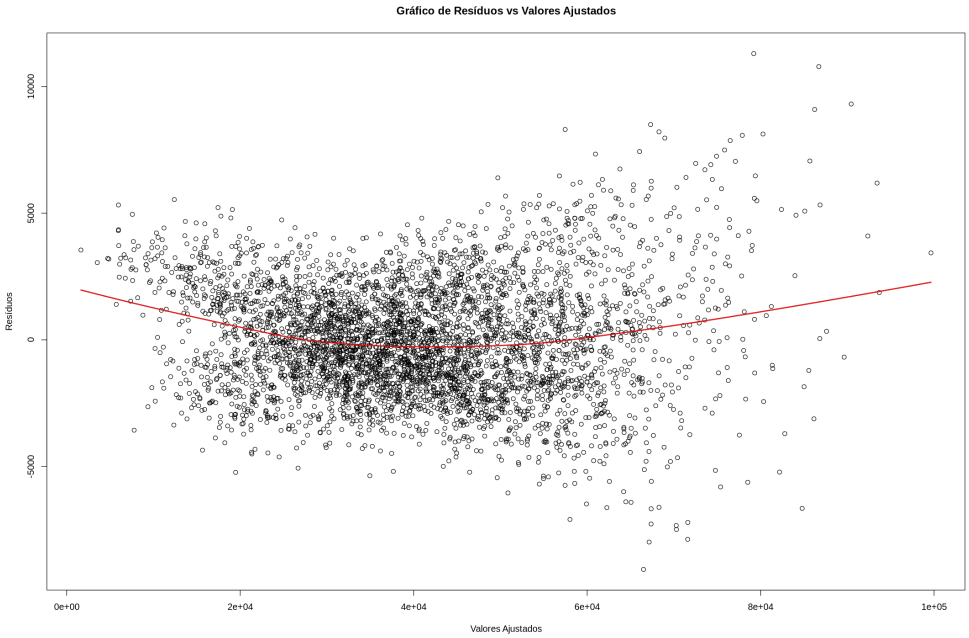

Nesse gráfico é possível observar um padrão de heterocedasticidade, caracterizado pela variabilidade dos resíduos conforme crescem os valores ajustados. Isso fica evidente no formato disperso dos pontos em relação à linha de regressão, com a amplitude dos resíduos (distância dos pontos à linha vermelha) variando de forma sistemática. Esse comportamento parece indicar que a suposição de homocedasticidade (variância constante dos erros) não é atendida, o que pode impactar negativamente a validade dos testes estatísticos e a confiabilidade das estimativas.

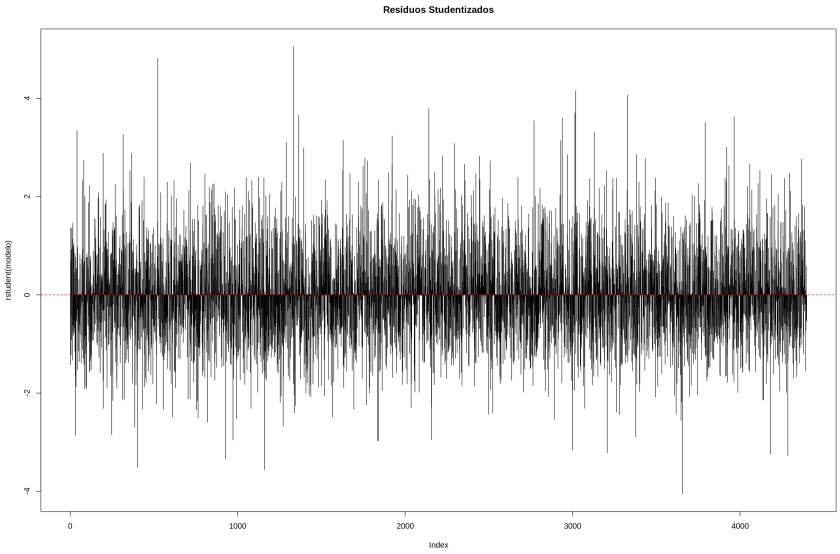

O gráfico acima nos ajuda a avaliar a suposição de erros não correlacionados (independência), Como o gráfico mostra resíduos “nervosos”, sem padrões de crescimento ou decrescimento, verificamos que a suposição está

satisfeita.

Normalidade

Plotamos um gráfico QQ-Plot, que é muito utilizado para verificar a normalidade dos resíduos em modelos de regressão.

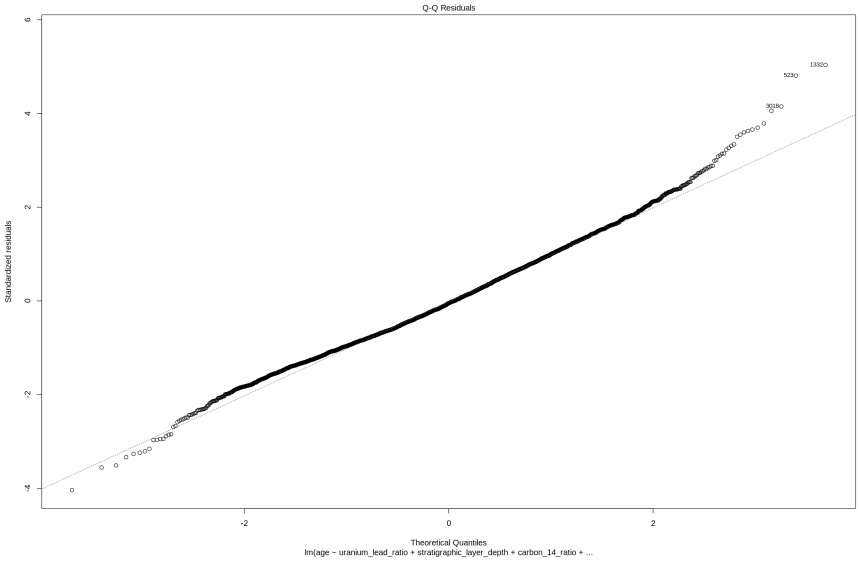

O gráfico nos indica uma violação da suposição de normalidade, mostrando assimetria.

Fizemos um teste de Shapiro-Wilk, também utilizado como um teste estatístico para verificar se uma amostra de dados segue uma distribuição normal. Valores mais próximos de 1 indicam que os dados estão mais próximos de uma distribuição normal.

```
        Shapiro-Wilk normality test

data:  modelo$residuals
W = 0.99362, p-value = 4.321e-13
```

O valor **W = 0.99362** indica que os resíduos estão próximos da normalidade, mas isso sozinho não é suficiente para concluir. Precisamos verificar o **p-valor = 4.321e-13**, que é um valor muito pequeno (menor que 0,05), o que nos leva a rejeitar a hipótese nula, a qual diz que os dados seguem uma distribuição normal. Isso significa que há evidências estatísticas de que os resíduos não seguem uma distribuição normal.

Outliers, Pontos Influentes e pontos discrepantes no domínio das regressoras

A seguir, temos um gráfico de resíduos Studentizados vs Valores ajustados. Conseguimos perceber que os pontos tornam-se mais dispersos e mais amplos ao longo do eixo X, contribuindo ainda mais para a hipótese de heterocedasticidade, mesmo que existam poucos outliers observados (pontos que estão acima e abaixo da primeira e terceira linhas).

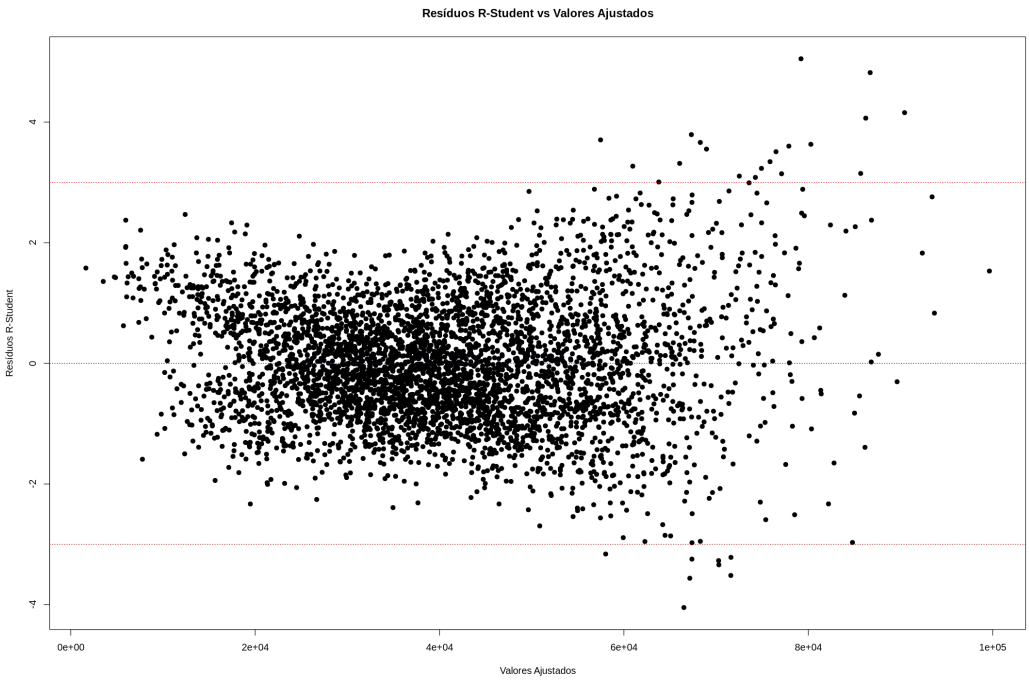

Como esperamos resíduos com valores entre -3 e 3, identificamos cerca de 27 outliers no nosso gráfico. Como não sabemos se os outliers encontrados se devem a erros de medida, decidimos por não removê-los do modelo.

DIstância de Cook:

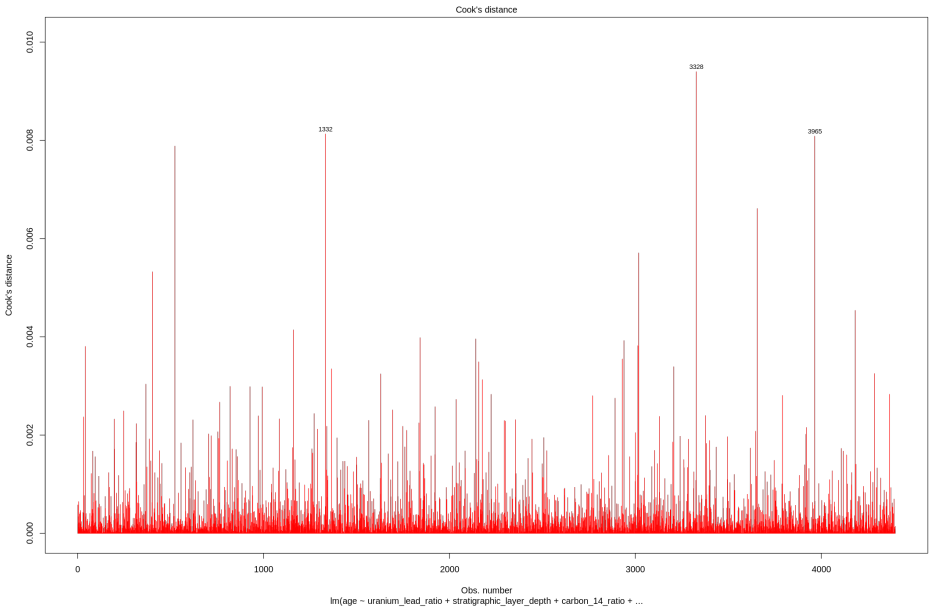

Medidas Corretivas

Conforme observado em nossas análises, as hipóteses de homocedasticidade e normalidade dos erros foram violadas. Com isso, as avaliações realizadas anteriormente, como os testes t e F utilizados para verificar a significância das variáveis independentes e do modelo como um todo, perdem sua validade.

Diante disso, é necessário buscar formas de induzir a homocedasticidade e a normalidade dos erros. Para tentar corrigir esses problemas, adotamos algumas medidas.

A primeira estratégia foi aplicar a transformação de Box-Cox à variável resposta. O procedimento retorna um valor de $\lambda \approx 0.83$ para ajuste com menor $SQRes(\lambda)$. Então, modificamos nossa variável resposta e nosso novo modelo é:

$$Y_i^{0.83} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_9 x_{i9} + \beta_{10} x_{i10} + \epsilon_i, \quad i = 1, \ldots, 4398$$

```
Call:
lm(formula = age^0.83 ~ uranium_lead_ratio + stratigraphic_layer_depth +
    carbon_14_ratio + radioactive_decay_series + paleomagnetic_data +
    surrounding_rock_type + stratigraphic_position, data = fossil)

Residuals:
     Min       1Q   Median       3Q      Max
-1249.67  -202.22    -2.09   200.49  1117.04

Coefficients:
                                     Estimate Std. Error t value Pr(>|t|)
(Intercept)                        1236.50617   21.19967  58.327  < 2e-16 ***
uranium_lead_ratio                 7175.64798   17.58740 407.999  < 2e-16 ***
stratigraphic_layer_depth             8.37586    0.05244 159.716  < 2e-16 ***
carbon_14_ratio                    1108.65360   19.38633  57.187  < 2e-16 ***
radioactive_decay_series            654.79754   15.70117  41.704  < 2e-16 ***
paleomagnetic_dataReversed polarity 249.60700   10.06052  24.811  < 2e-16 ***
surrounding_rock_typeLimestone      116.54901   15.13456   7.701 1.66e-14 ***
surrounding_rock_typeSandstone       57.54920   14.57132   3.949 7.95e-05 ***
surrounding_rock_typeShale          155.31892   15.19072  10.225  < 2e-16 ***
stratigraphic_positionMiddle       -965.27493   10.22951 -94.362  < 2e-16 ***
stratigraphic_positionTop          -985.78818   15.08460 -65.351  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 299.7 on 4387 degrees of freedom
Multiple R-squared:  0.9793,    Adjusted R-squared:  0.9792
F-statistic: 2.073e+04 on 10 and 4387 DF,  p-value: < 2.2e-16
```

O R^2_{adj} continua com o valor alto e próximo ao que tínhamos anteriormente. Nossas variáveis continuaram sendo significantes pelo teste t e o mesmo vale para a estatística F. Obtivemos as seguintes análises:

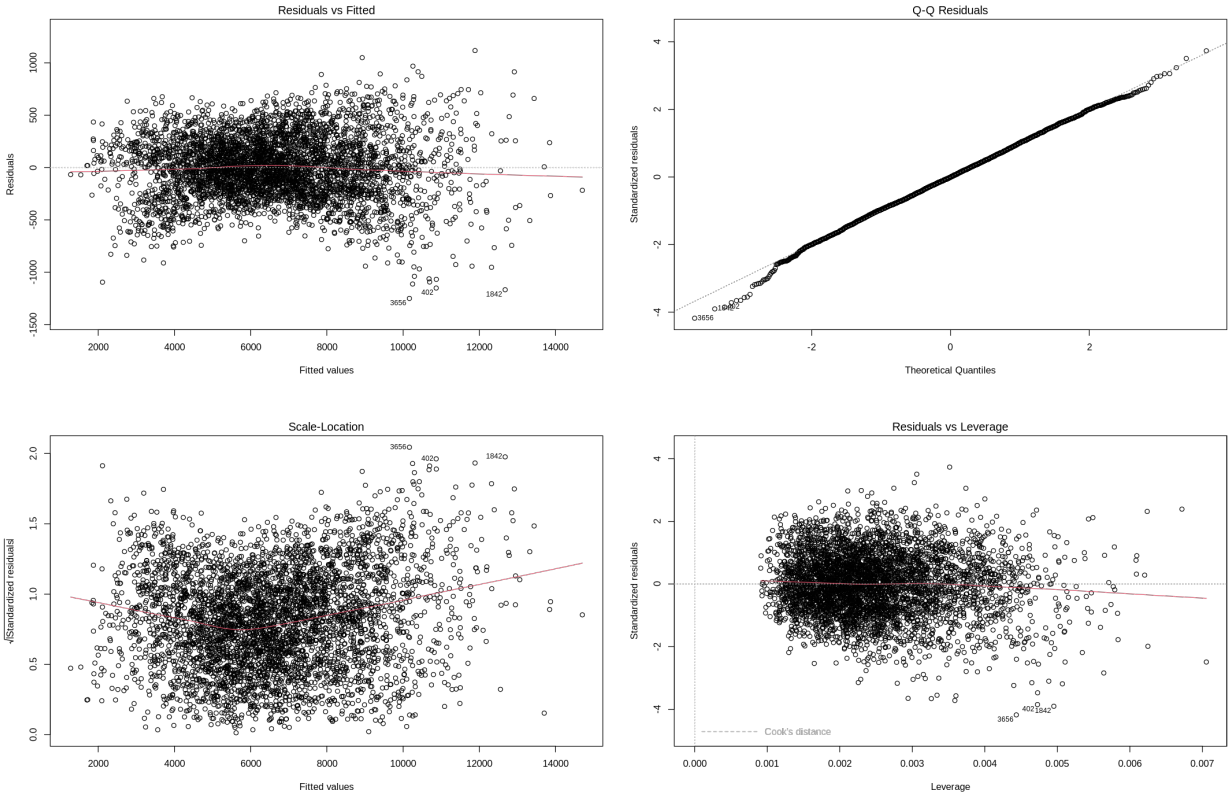

Fizemos outro modelo deixando apenas 3 variáveis: uranium_lead_ratio, stratigraphic_layer_depth e stratigraphic_position, pois tinham correlação mais significativa com a variável resposta.

```
Call:
lm(formula = age^0.83 ~ uranium_lead_ratio + stratigraphic_layer_depth +
    stratigraphic_position, data = fossil)

Residuals:
     Min       1Q   Median       3Q      Max
-2023.96  -297.59   -10.53   295.86  1878.15

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
(Intercept)                 2209.51910   19.84015  111.37   <2e-16 ***
uranium_lead_ratio          7195.66396   26.58573  270.66   <2e-16 ***
stratigraphic_layer_depth      8.39614    0.07923  105.97   <2e-16 ***
stratigraphic_positionMiddle -965.15833   15.46334  -62.42   <2e-16 ***
stratigraphic_positionTop    -981.08004   22.79953  -43.03   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 453.2 on 4393 degrees of freedom
Multiple R-squared:  0.9525,    Adjusted R-squared:  0.9525
F-statistic: 2.204e+04 on 4 and 4393 DF,  p-value: < 2.2e-16
```

Ao plotar os resíduos deste modelo, obtivemos uma melhora considerável para o pressuposto de normalidade comparado com o modelo anterior.

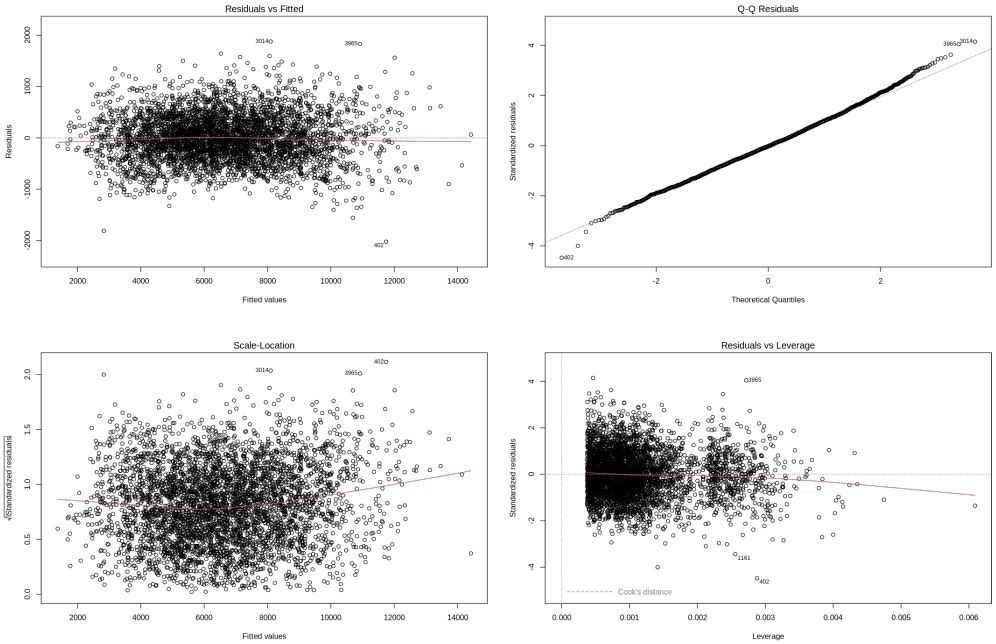

Ridge

A seguir, realizamos uma Regressão Ridge para comparar os coeficientes assim obtidos com aqueles obtidos pelo modelo anterior.

O gráfico abaixo mostra os erros quadráticos médios associados a diferentes valores de $log(\lambda)$, onde λ é o parâmetro da Regressão Ridge.

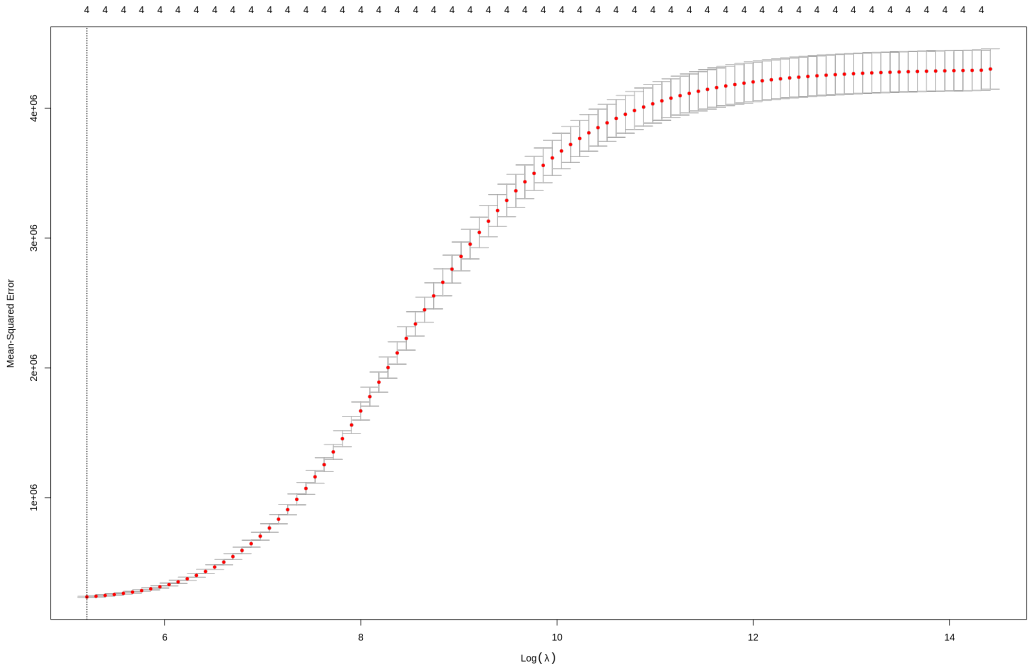

Depois, usamos um comando no R para buscar o valor de λ que minimize esse erro. O valor encontrado foi $\lambda \approx 182.53$, e os coeficientes do modelo são apresentados abaixo.

	x
(Intercept)	2564.287326
uranium_lead_ratio	6607.001519
stratigraphic_layer_depth	7.693745
stratigraphic_positionMiddle	-870.783085

Embora os coeficientes não sejam tão próximos àqueles obtidos pelo último modelo, ainda se encontram na mesma ordem de grandeza.

Lasso

Então, fazemos o mesmo com a Regressão Lasso. Abaixo, o gráfico do EQM e o parâmetro ótimo da regressão é $\lambda \approx 6.26$.

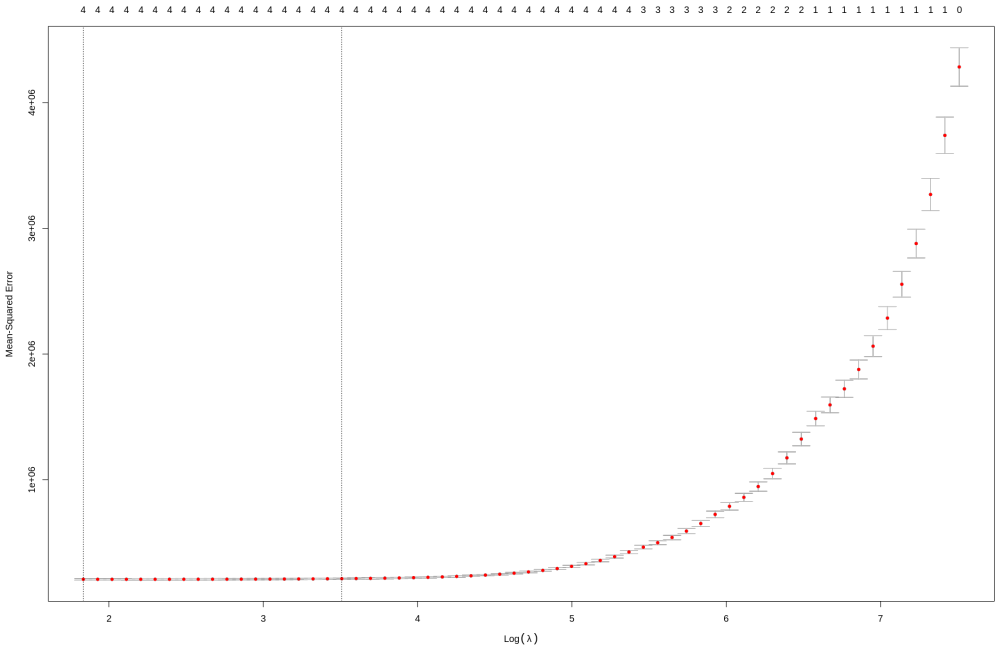

Enfim, os coeficientes segundo a regressão:

	x
(Intercept)	2225.109977
uranium_lead_ratio	7170.462878
stratigraphic_layer_depth	8.322665
stratigraphic_positionMiddle	-947.344363

Vemos que os coeficientes por este método são mais próximos daqueles do nosso modelo.